

Algoritmos fundamentales de Machine Learning

Material didáctico

29 de septiembre de 2026

Resumen

Este documento presenta siete algoritmos fundamentales de aprendizaje automático: regresión lineal, regresión polinómica, regresión logística, K-means, K-Nearest Neighbors (K-NN), Máquinas de Vectores de Soporte (SVM) y Random Forest. Para cada uno se explica el problema que resuelve, su formulación matemática, el funcionamiento paso a paso y los principales aspectos que deben tenerse en cuenta al aplicarlo.

Índice

1. Introducción	3
2. Visión general	3
3. Regresión lineal	3
3.1. Qué es	3
3.2. Modelo matemático	3
3.3. Funcionamiento paso a paso	4
3.4. Evaluación	4
3.5. Aspectos a tener en cuenta	4
4. Regresión polinómica	5
4.1. Qué es	5
4.2. Modelo matemático	5
4.3. Funcionamiento	5
4.4. Ejemplo	5
4.5. Limitaciones	5
5. Regresión logística	7
5.1. Qué es	7
5.2. Modelo matemático	7
5.3. Regla de decisión	7
5.4. Interpretación	7
5.5. Evaluación	7
6. K-means	9
6.1. Qué es	9
6.2. Objetivo	9
6.3. Funcionamiento	9
6.4. Selección de K	9
6.5. Limitaciones	9

7. K-Nearest Neighbors (K-NN)	11
7.1. Qué es	11
7.2. Distancia	11
7.3. Funcionamiento	11
7.4. Elección de K	11
7.5. Limitaciones	11
8. Máquinas de Vectores de Soporte (SVM)	13
8.1. Qué es	13
8.2. Formulación	13
8.3. Vectores de soporte	13
8.4. Kernels	13
8.5. SVM para regresión	13
8.6. Aspectos a tener en cuenta	13
9. Random Forest	15
9.1. Qué es	15
9.2. Funcionamiento	15
9.3. Clasificación	15
9.4. Regresión	15
9.5. Por qué se utilizan muchos árboles	15
9.6. Ventajas y limitaciones	15
10.Comparación conceptual	17
11.Flujo común de un proyecto de Machine Learning	17
12.Conclusión	17

1. Introducción

Un algoritmo de Machine Learning transforma datos de entrada en un modelo capaz de describir patrones, realizar predicciones o descubrir estructuras. La elección del algoritmo depende, entre otros factores, de la variable objetivo, la naturaleza de los datos, la dimensionalidad, el tamaño del conjunto de datos, la necesidad de interpretabilidad y el coste computacional.

Los algoritmos estudiados pueden organizarse conceptualmente en:

- **Aprendizaje supervisado:** regresión lineal, regresión polinómica, regresión logística, K-NN, SVM y Random Forest.
- **Aprendizaje no supervisado:** K-means.
- **Regresión:** regresión lineal, regresión polinómica, K-NN, SVR y Random Forest.
- **Clasificación:** regresión logística, K-NN, SVM y Random Forest.

2. Visión general

Cuadro 1: Resumen conceptual de los algoritmos.

Algoritmo	Tipo	Salida	Idea central
Regresión lineal	Supervisado	Valor continuo	Recta o hiperplano ajustado
Regresión polinómica	Supervisado	Valor continuo	Potencias de las variables
Regresión logística	Supervisado	Clase/probabilidad	Sigmoide sobre una combinación lineal
K-means	No supervisado	Clusters	Distancia a centroides
K-NN	Supervisado	Clase o valor	Vecinos más próximos
SVM	Supervisado	Clase o valor	Margen, hiperplano y kernels
Random Forest	Ensemble supervisado	Clase o valor	Agregación de árboles

3. Regresión lineal

3.1. Qué es

La regresión lineal modela la relación entre una o varias variables independientes y una variable dependiente numérica continua. En el caso simple, el modelo busca una recta que se ajuste a los datos.

Idea principal

La regresión lineal encuentra una recta que mejor se ajusta a los datos para predecir un valor numérico continuo.

3.2. Modelo matemático

La regresión lineal simple se expresa como:

$$\hat{Y} = \beta_0 + \beta_1 X.$$

Donde $\hat{Y}$ es el valor predicho, β_0 el intercepto, β_1 la pendiente y X la variable independiente. Los coeficientes pueden estimarse mediante mínimos cuadrados ordinarios:

$$\min_{\beta_0, \beta_1} \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2.$$

3.3. Funcionamiento paso a paso

1. Definir las variables de entrada y la variable objetivo.
2. Ajustar los coeficientes del modelo.
3. Obtener las predicciones.
4. Calcular los residuos:

$$e_i = y_i - \hat{y}_i.$$

5. Evaluar el modelo mediante métricas como R^2 , MAE y RMSE.

3.4. Evaluación

El coeficiente R^2 permite expresar la proporción de variabilidad explicada por el modelo. MAE y RMSE permiten cuantificar el error de predicción.

3.5. Aspectos a tener en cuenta

La interpretación del modelo requiere revisar la relación entre las variables, los residuos y los supuestos estadísticos relevantes, como linealidad, independencia y homocedasticidad.




Figura 1: Infografía didáctica: regresión lineal.

4. Regresión polinómica

4.1. Qué es

La regresión polinómica extiende la regresión lineal incorporando potencias de las variables para representar relaciones curvas o no lineales.

Idea principal

La regresión polinómica puede capturar relaciones no lineales mediante características como X^2 , X^3 , etc.

4.2. Modelo matemático

Un polinomio de grado n puede expresarse como:

$$\hat{Y} = \beta_0 + \beta_1 X + \beta_2 X^2 + \cdots + \beta_n X^n.$$

Aunque la curva resultante sea no lineal respecto a X , el modelo es lineal respecto a sus parámetros β .

4.3. Funcionamiento

1. Construir las características polinómicas.
2. Ajustar los coeficientes mediante regresión.
3. Comparar diferentes grados.
4. Evaluar mediante validación.
5. Seleccionar una complejidad que no produzca sobreajuste.

4.4. Ejemplo


Para un modelo de segundo grado:

$$\hat{Y} = \beta_0 + \beta_1 X + \beta_2 X^2.$$

El término X^2 permite representar una relación curvada que una recta simple no puede representar.

4.5. Limitaciones

Un grado excesivamente elevado puede producir sobreajuste y generar extrapolaciones poco fiables.



5. Regresión logística

5.1. Qué es

La regresión logística es un modelo supervisado utilizado principalmente para clasificación binaria. En lugar de producir directamente una clase, estima la probabilidad de pertenencia a una clase.

Idea principal

La regresión logística transforma una combinación lineal de las variables en una probabilidad mediante la función sigmoide.

5.2. Modelo matemático

Primero se calcula:

$$z = \beta_0 + \beta_1 X_1 + \cdots + \beta_n X_n.$$

Después se aplica la función sigmoide:

$$p(y = 1 | X) = \sigma(z) = \frac{1}{1 + e^{-z}}.$$

El resultado está comprendido entre 0 y 1.

5.3. Regla de decisión

Con un umbral t , una regla sencilla es:

$$\hat{y} = \begin{cases} 1 & \text{si } p(y = 1 | X) \geq t, \\ 0 & \text{si } p(y = 1 | X) < t. \end{cases}$$

5.4. Interpretación

Los coeficientes se interpretan sobre los log-odds:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_n X_n.$$

El término e^{β_i} puede interpretarse como multiplicador de los odds asociado a una unidad de cambio de X_i , manteniendo constantes las demás variables.

5.5. Evaluación

En clasificación pueden utilizarse accuracy, precision, recall, F1, matriz de confusión y ROC-AUC, dependiendo del problema.




Figura 3: Infografía didáctica: regresión logística.

6. K-means

6.1. Qué es

K-means es un algoritmo de aprendizaje no supervisado que divide los datos en K grupos o clusters. Cada grupo se representa mediante un centroide.

Idea principal

K-means asigna los puntos al centroide más próximo y recalcula los centroides hasta alcanzar una condición de convergencia.

6.2. Objetivo

Para cada cluster C_k , su centroide se calcula como:

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i.$$

El algoritmo intenta minimizar la suma de distancias cuadráticas intracluster:

$$\sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2.$$

6.3. Funcionamiento

1. Seleccionar el número de clusters K .
2. Inicializar K centroides.
3. Asignar cada punto al centroide más cercano.
4. Recalcular cada centroide.
5. Repetir los pasos de asignación y actualización.
6. Detenerse cuando los centroides dejen de cambiar significativamente o se alcance el máximo de iteraciones.

6.4. Selección de K

El método del codo puede utilizarse para explorar diferentes valores de K . También pueden emplearse otras medidas de evaluación del clustering, según el objetivo del análisis.

6.5. Limitaciones

K-means es sensible a la escala de las variables, a la inicialización, a la presencia de valores atípicos y a la geometría de los clusters.




Figura 4: Infografía didáctica: K-means.

7. K-Nearest Neighbors (K-NN)

7.1. Qué es

K-NN realiza una predicción utilizando los ejemplos de entrenamiento más cercanos a un nuevo punto. Puede emplearse tanto para clasificación como para regresión.

Idea principal

La idea central es que observaciones próximas en el espacio de características pueden presentar respuestas similares.

7.2. Distancia

Una distancia euclídea habitual es:

$$d(x, x_i) = \sqrt{\sum_{j=1}^n (x_j - x_{ij})^2}.$$

7.3. Funcionamiento

1. Normalizar las variables cuando sea necesario.
2. Calcular la distancia entre el nuevo punto y las observaciones.
3. Ordenar las observaciones según la distancia.
4. Seleccionar los K vecinos más próximos.
5. En clasificación, utilizar la votación mayoritaria.
6. En regresión, calcular normalmente la media o mediana de los valores de los vecinos.

7.4. Elección de K

Con $K = 1$ la predicción depende de un único vecino. Con valores mayores, la decisión se suaviza al considerar más observaciones.

7.5. Limitaciones

El algoritmo es sensible a la escala de las variables y puede resultar costoso en conjuntos de datos grandes. En espacios de alta dimensionalidad la distancia puede perder capacidad discriminativa.




Figura 5: Infografía didáctica: K-Nearest Neighbors.

8. Máquinas de Vectores de Soporte (SVM)

8.1. Qué es

SVM busca un hiperplano que separe las clases maximizando el margen entre ellas. Los puntos próximos a la frontera reciben el nombre de vectores de soporte.

Idea principal

La idea fundamental de SVM es encontrar una frontera de decisión con un margen amplio entre las clases.

8.2. Formulación

En el caso lineal separable, una formulación habitual es:

$$\min \frac{1}{2} \|w\|^2$$

sujeto a:

$$y_i(w^T x_i + b) \geq 1.$$

8.3. Vectores de soporte

Los vectores de soporte son los ejemplos de entrenamiento más próximos a la frontera y desempeñan un papel fundamental en la definición del modelo.

8.4. Kernels

Cuando los datos no son separables linealmente, pueden utilizarse funciones kernel. Entre las familias habituales se encuentran:

- lineal;
- polinómica;
- RBF o gaussiana;
- sigmoide.

8.5. SVM para regresión

En regresión puede utilizarse SVR. El objetivo es obtener una función con una zona de tolerancia ε alrededor de las predicciones.

8.6. Aspectos a tener en cuenta

La elección del kernel y de hiperparámetros como C y γ puede modificar sustancialmente el comportamiento del modelo. El coste computacional puede aumentar con conjuntos de datos grandes.




Figura 6: Infografía didáctica: Máquinas de Vectores de Soporte.

9. Random Forest

9.1. Qué es

Random Forest es un método de ensemble basado en múltiples árboles de decisión. Cada árbol se entrena con una muestra bootstrap y utiliza subconjuntos aleatorios de variables en las divisiones.

Idea principal

Random Forest combina muchos árboles de decisión y agrega sus predicciones para obtener un modelo ensemble.

9.2. Funcionamiento

1. Partir del conjunto de entrenamiento.
2. Generar múltiples muestras bootstrap.
3. Entrenar un árbol con cada muestra.
4. En cada división, considerar un subconjunto aleatorio de características.
5. Obtener la predicción de cada árbol.
6. Agregar las predicciones.

9.3. Clasificación

Para clasificación, una forma habitual de agregación es el voto mayoritario:

$$\hat{y} = \text{modo}(f_1(x), f_2(x), \dots, f_T(x)).$$

9.4. Regresión

Para regresión, puede utilizarse el promedio:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T f_t(x).$$

9.5. Por qué se utilizan muchos árboles

Un árbol individual puede presentar una elevada variabilidad. El muestreo de datos y variables introduce diversidad entre los árboles y la agregación reduce la dependencia de una única estructura.

9.6. Ventajas y limitaciones

Entre sus características se encuentran la capacidad para modelar relaciones no lineales y su aplicabilidad a problemas de clasificación y regresión. Como contrapartida, el ensemble requiere más memoria y tiempo de cálculo y resulta menos interpretable que un único árbol.




Figura 7: Infografía didáctica: Random Forest.

10. Comparación conceptual

Cuadro 2: Comparación de los algoritmos estudiados.

Algoritmo	Aprendizaje	Problema	Principio
Regresión lineal	Supervisado	Regresión	Ajuste lineal mediante mínimos cuadrados.
Regresión polinómica	Supervisado	Regresión	Transformación polinómica y ajuste lineal.
Regresión logística	Supervisado	Clasificación	Probabilidad mediante función sigmoide.
K-means	No supervisado	Clustering	Asignación iterativa a centroides.
K-NN	Supervisado	Clasificación/regresión	Predicción basada en vecinos próximos.
SVM	Supervisado	Clasificación/regresión	Optimización del margen y kernels.
Random Forest	Supervisado	Clasificación/regresión	Agregación de múltiples árboles.

11. Flujo común de un proyecto de Machine Learning

Un flujo general puede organizarse de la siguiente manera:

1. **Definir el problema:** determinar qué se desea predecir o descubrir.
2. **Preparar los datos:** limpieza, codificación, normalización y selección o transformación de características.
3. **Separar los datos:** entrenamiento, validación y prueba, según el diseño experimental.
4. **Entrenar:** ajustar los parámetros del modelo.
5. **Ajustar hiperparámetros:** seleccionar configuraciones mediante validación.
6. **Evaluar:** utilizar datos no empleados para ajustar el modelo.
7. **Analizar errores:** estudiar residuos, errores de clasificación y posibles sesgos del procedimiento.
8. **Documentar:** registrar datos, transformaciones, configuración, métricas y resultados.

12. Conclusión

Los siete algoritmos presentan mecanismos diferentes para aprender a partir de los datos. Las regresiones modelan relaciones entre variables, K-means descubre grupos, K-NN utiliza similitud local, SVM construye fronteras con margen y Random Forest combina múltiples árboles.

La selección de un algoritmo debe realizarse en función del problema y de las características del conjunto de datos, acompañando siempre el modelo con un procedimiento de evaluación adecuado.