

Caso práctico de aplicación de inteligencia artificial

Ayuntamiento de Madrid

Diseño de un asistente para clasificar y derivar avisos ciudadanos

José Manuel Aroca Fernández

Octubre de 2026

Resumen

Este documento desarrolla una propuesta didáctica de piloto para utilizar inteligencia artificial como herramienta de apoyo a la clasificación, resumen y derivación de avisos ciudadanos. La solución se diseña con intervención humana, minimización de datos y trazabilidad. El caso es hipotético: no afirma que el Ayuntamiento de Madrid haya implantado este sistema. Se toma como contexto la estrategia municipal de IA y gobierno del dato publicada por el propio Ayuntamiento, y se propone una metodología de evaluación jurídica, técnica y organizativa antes de cualquier despliegue.

Índice general

1. Contexto y definición del caso	3
1.1. Contexto municipal	3
1.2. Problema que se quiere resolver	3
1.3. Propuesta	3
1.4. Objetivos y límites	4
2. Alcance funcional y flujo operativo	5
2.1. Flujo propuesto	5
2.2. Fuera de alcance	5
3. Datos, arquitectura y seguridad	7
3.1. Datos de entrada	7
3.2. Arquitectura de referencia	7
3.3. Seguridad	7
4. Clasificación regulatoria y cumplimiento	8
4.1. Reglamento europeo de IA	8
4.2. Obligaciones y controles a comprobar	8
4.3. RGPD y evaluación de impacto	9
4.4. ISO/IEC como marco de gestión	9
5. Registro inicial de riesgos	10
5.1. Matriz ilustrativa	10
6. Plan de pruebas y evaluación	12
6.1. Diseño de la prueba	12
6.2. Pruebas mínimas	12
6.3. Criterios de salida del piloto	12
6.4. Métricas	13
7. Gobernanza, roles y contratación	14
7.1. Roles propuestos	14
7.2. Condiciones contractuales	14
8. Hoja de ruta de implantación	15
8.1. Condiciones para detener o pausar	15
9. Conclusiones	16
A. Ejemplos de datos sintéticos	17
B. Checklist de aprobación	18

Índice de figuras

1.1. Arquitectura conceptual del piloto propuesto. No representa una arquitectura municipal existente.	4
2.1. Flujo propuesto desde la entrada hasta el registro auditado.	5
5.1. Matriz simple de probabilidad e impacto. La escala se debe adaptar al método municipal aprobado.	10

Capítulo 1

Contexto y definición del caso

1.1. Contexto municipal

El Ayuntamiento de Madrid ha publicado una estrategia de inteligencia artificial orientada a servicios digitales para las personas, inteligencia de ciudad e innovación, junto con objetivos de licitud, ética, robustez, transparencia, seguridad y protección de derechos. Su información pública describe además un enfoque de gobernanza transversal y un inventario municipal de algoritmos. Este caso se alinea conceptualmente con ese marco, pero constituye una propuesta académica independiente y no una descripción de un sistema municipal en producción [1, 2].

1.2. Problema que se quiere resolver


Los canales de atención municipal pueden recibir comunicaciones de naturaleza diversa: incidencias en vía pública, limpieza, alumbrado, consultas informativas y solicitudes que requieren derivación a una unidad especializada. La clasificación manual puede exigir tiempo y producir asignaciones incorrectas, especialmente cuando el texto es ambiguo o está incompleto.

1.3. Propuesta

Construir un asistente que:

- sugiera una categoría temática y una unidad municipal de destino a partir del texto del aviso;
- genere un resumen breve para facilitar la lectura del personal;
- señale mensajes ambiguos, posibles urgencias y presencia potencial de datos sensibles;
- muestre la confianza estimada y permita corregir la sugerencia;
- registre la decisión final adoptada por la persona autorizada.

El sistema no resolverá expedientes, no denegará solicitudes, no determinará derechos ni comunicará decisiones administrativas de forma autónoma.

Arquitectura conceptual del piloto (no representa un sistema municipal existente)

La IA recomienda; el personal municipal valida. No se resuelven solicitudes ni se deniegan derechos automáticamente.

Figura 1.1: Arquitectura conceptual del piloto propuesto. No representa una arquitectura municipal existente.

1.4. Objetivos y límites


Objetivo	Indicador inicial propuesto
Reducir tiempo de triaje	Mediana de tiempo por aviso frente al proceso base.
Mejorar asignación	Porcentaje de categorías aceptadas sin cambio por el personal.
Evitar errores críticos	Cero decisiones administrativas automatizadas; derivación humana de casos críticos.
Mejorar trazabilidad	Porcentaje de sugerencias con versión de modelo, fecha y validación registrada.
Proteger datos	Incidentes de privacidad y cumplimiento de plazos de eliminación.

Cuadro 1.1: Objetivos evaluables. Los umbrales deben acordarse antes del piloto.

Capítulo 2

Alcance funcional y flujo operativo

2.1. Flujo propuesto



Punto de control: si la confianza es baja, hay urgencia, datos sensibles o posible daño, derivación a una persona.

Figura 2.1: Flujo propuesto desde la entrada hasta el registro auditado.

1. Recepción del aviso por un canal municipal autorizado.
2. Validación de formato y eliminación o enmascaramiento de datos que no sean necesarios para clasificar.
3. La IA propone categoría, resumen y unidad de destino utilizando un catálogo aprobado.
4. Un empleado municipal revisa, corrige o rechaza la propuesta.
5. Solo tras la validación se registra o deriva el aviso en el sistema de gestión existente.
6. Las métricas de calidad, errores y correcciones se revisan periódicamente.

2.2. Fuera de alcance

- Resolver procedimientos administrativos o emitir actos con efectos jurídicos.
- Priorizar el acceso de una persona a prestaciones o servicios esenciales mediante perfiles personales.

- Inferir atributos sensibles, emociones, peligrosidad o credibilidad de la ciudadanía.
- Entrenar modelos con mensajes reales sin evaluación jurídica, base válida y controles aprobados.
- Usar datos de ubicación personal o identificadores para finalidades incompatibles.

Punto de control. Si durante el diseño se cambia la finalidad y el sistema comienza a influir en decisiones sobre derechos, servicios esenciales o personas, debe repetirse la clasificación regulatoria y la evaluación de impacto antes de continuar.

Capítulo 3

Datos, arquitectura y seguridad

3.1. Datos de entrada

Se propone comenzar con textos sintéticos y, en una fase posterior, con una muestra histórica autorizada y minimizada. Los campos mínimos podrían ser:

- identificador interno seudónimo del aviso;
- texto necesario para comprender la incidencia;
- categoría confirmada por el personal;
- unidad de destino y correcciones realizadas;
- marca temporal y versión del modelo.

Los nombres, teléfonos, direcciones particulares, documentos identificativos y datos de salud deben excluirse o enmascarse salvo que exista una necesidad demostrada y una base jurídica apropiada. Los datos seudonimizados siguen pudiendo ser datos personales.

3.2. Arquitectura de referencia

- **Capa de entrada:** autenticación, validación y minimización.
- **Servicio de IA:** clasificación y resumen; no ejecuta acciones administrativas.
- **Catálogo municipal:** categorías y destinos controlados, versionados y mantenidos por las unidades responsables.
- **Interfaz de revisión:** muestra texto original autorizado, sugerencia, nivel de confianza y opción de corrección.
- **Integración:** solo transmite el resultado confirmado al gestor municipal.
- **Auditoría:** registra versión del modelo, sugerencia, corrección, usuario autorizado y fecha, con controles de acceso y conservación.

3.3. Seguridad

Aplicar mínimo privilegio, autenticación robusta, cifrado en tránsito y almacenamiento, segregación de entornos, gestión de secretos, análisis de vulnerabilidades, registros de acceso, copias de seguridad y un procedimiento de respuesta a incidentes. La contratación debe precisar ubicación y subencargados, reutilización de datos, confidencialidad, eliminación, auditoría, portabilidad y notificación de incidentes.

Capítulo 4

Clasificación regulatoria y cumplimiento

4.1. Reglamento europeo de IA

La clasificación no se puede concluir únicamente por la tecnología utilizada. Deben analizarse finalidad prevista, funciones reales, población afectada, integración con procesos municipales y versión vigente del Reglamento (UE) 2024/1689, modificado por el Reglamento (UE) 2026/1744 [3, 4]. En la configuración limitada descrita, el sistema se plantea como apoyo administrativo para organizar avisos, sin determinar derechos ni sustituir decisiones humanas. Esto no equivale a una conclusión jurídica definitiva de que quede fuera de alto riesgo. Antes del piloto, la unidad jurídica y de gobernanza debe documentar la clasificación, revisar el anexo III y analizar si el uso concreto puede encajar en alguna categoría regulada.

4.2. Obligaciones y controles a comprobar

Área	Pregunta de cumplimiento	Evidencia propuesta
Finalidad y clasificación	¿Está definido el propósito y documentada la categoría regulatoria?	Ficha del sistema, análisis jurídico y aprobación.
Transparencia	¿Se informa al personal y, si interactúa directamente, a la ciudadanía sobre el uso de IA cuando corresponda?	Aviso de transparencia y guía de uso.
Supervisión humana	¿Puede el empleado corregir o rechazar cada sugerencia?	Diseño de interfaz, procedimiento y logs de corrección.
Datos	¿Se conocen origen, base jurídica, minimización y conservación?	Registro de tratamiento y evaluación de privacidad.
Riesgos	¿Se identifican fallos, sesgos y daños previsibles?	Registro de riesgos, pruebas y medidas de mitigación.
Trazabilidad	¿Puede reconstruirse qué sugirió el sistema y qué validó el empleado?	Logs controlados, versiones y política de retención.
Proveedores	¿Se controlan subencargados, reutilización de datos y cambios del servicio?	Pliego, contrato, SLA y evaluación de proveedor.

Área	Pregunta de cumplimiento	Evidencia propuesta
Incidentes	¿Existe procedimiento de escalamado y comunicación?	Plan de respuesta, responsables y simulacros.

4.3. RGPD y evaluación de impacto

Debe determinarse el responsable del tratamiento, la finalidad, la base jurídica del artículo 6 del RGPD y, cuando existan categorías especiales de datos, la aplicabilidad del artículo 9. La evaluación de impacto relativa a la protección de datos (EIPD) será necesaria si el tratamiento probablemente entrañe un alto riesgo para los derechos y libertades, conforme al artículo 35 y a los criterios aplicables [5]. No debe confundirse la EIPD con la evaluación de impacto sobre derechos fundamentales del AI Act, cuando esta última sea exigible.

4.4. ISO/IEC como marco de gestión

- **ISO/IEC 42001:2023:** definir alcance, responsabilidades, política, evaluación del desempeño y mejora del sistema de gestión de IA.
- **ISO/IEC 23894:2023:** estructurar identificación, análisis, evaluación, tratamiento y monitorización de riesgos.
- **ISO/IEC 42005:2025:** orientar la evaluación de impactos sobre personas, colectivos y sociedad.

Estas normas pueden apoyar la gobernanza y la producción de evidencias, pero no sustituyen las obligaciones legales.

Capítulo 5

Registro inicial de riesgos

5.1. Matriz ilustrativa

Las valoraciones de la tabla son hipótesis iniciales para iniciar un taller de riesgos; no son resultados medidos ni una aceptación formal del riesgo.




Figura 5.1: Matriz simple de probabilidad e impacto. La escala se debe adaptar al método municipal aprobado.

ID	Riesgo	Prob. inicial	Impacto	Controles propuestos
R1	Clasificación errónea	Media	Alta	Revisión humana, umbral de confianza, corrección y métricas por categoría.
R2	Exposición de datos	Media	Alta	Minimización, redacción, accesos, retención limitada y evaluación RGPD.

ID	Riesgo	Prob. inicial	Impacto	Controles propuestos
R3	Sesgo lingüístico o territorial	Media	Media/alta	Pruebas por barrio y variedad lingüística, muestras representativas y revisión.
R4	Resumen incorrecto	Media	Alta	No generar respuestas definitivas; comparar con texto original y validar.
R5	Falta de accesibilidad	Media	Media	Canales alternativos, lenguaje claro y pruebas con perfiles diversos.
R6	Uso secundario de mensajes	Baja/media	Alta	Limitar finalidad; prohibir entrenamiento no autorizado y evaluar cambios.
R7	Incidente de ciberseguridad	Media	Alta	Cifrado, autenticación, pruebas, monitorización y respuesta a incidentes.
R8	Clasificación legal equivocada	Baja/media	Alta	Revisión jurídica formal antes del piloto y cuando cambie el uso.

El registro editable se incluye en `datos/registro_riesgos.csv`.

Capítulo 6

Plan de pruebas y evaluación

6.1. Diseño de la prueba

Se propone una prueba controlada con datos sintéticos y, tras las autorizaciones, una muestra representativa minimizada. La etiqueta de referencia debe ser revisada por personal municipal. Separar los datos de desarrollo y evaluación y evitar que mensajes casi duplicados aparezcan en ambos conjuntos.

6.2. Pruebas mínimas

1. **Calidad de clasificación:** precisión, exhaustividad y F1 por categoría, además de matriz de confusión.
2. **Derivación:** porcentaje de unidad de destino correcta y tasa de corrección humana.
3. **Ambigüedad:** proporción de casos correctamente enviados a revisión humana.
4. **Privacidad:** detección y minimización de datos personales en el texto.
5. **Robustez:** errores tipográficos, lenguaje coloquial, mensajes largos, varios asuntos y entradas maliciosas.
6. **Accesibilidad e inclusión:** desempeño con variedades lingüísticas y lenguaje sencillo.
7. **Seguridad:** pruebas de acceso, inyección de instrucciones, fuga de información y aislamiento de datos.
8. **Operación:** latencia, disponibilidad, coste por aviso y capacidad de recuperación.

6.3. Criterios de salida del piloto

Antes de probar, el comité debe fijar umbrales cuantitativos y reglas de parada. Como ejemplo didáctico, exigir una tasa mínima acordada de clasificación correcta en categorías críticas, una tasa máxima de errores graves, trazabilidad completa, ausencia de incidentes de privacidad sin resolver y aprobación formal de las unidades jurídica, seguridad, protección de datos y negocio. Los umbrales definitivos deben definirse con datos de referencia, no elegirse después de observar los resultados.

6.4. Métricas

Métrica	Interpretación
Macro-F1	Equilibra desempeño entre categorías, incluso si hay clases minoritarias.
Tasa de corrección	Porcentaje de sugerencias cambiadas por el personal.
Tasa de escalado	Casos enviados a revisión manual por ambigüedad o riesgo.
Tiempo de triaje	Comparación antes/después sin sacrificar calidad.
Errores críticos	Casos mal derivados con consecuencias relevantes.
Incidentes de privacidad	Incidentes confirmados y tiempo de resolución.
Satisfacción del empleado	Utilidad percibida y carga de revisión.

Cuadro 6.1: Indicadores sugeridos para el cuadro de mando del piloto.

Capítulo 7

Gobernanza, roles y contratación

7.1. Roles propuestos

Rol	Responsabilidad principal
Patrocinador del servicio	Define necesidad pública, objetivos y aceptación del resultado.
Unidad municipal propietaria	Mantiene catálogo de categorías, procedimiento y calidad de datos.
Oficina Digital / gobernanza IA	Coordina criterios de gobernanza, inventario y revisión transversal.
Informática municipal	Arquitectura, integración, operación y continuidad.
Delegado/a de Protección de Datos	Asesora sobre RGPD y necesidad de EIPD.
Asesoría jurídica	Clasificación normativa, contratación y revisión de obligaciones.
Seguridad de la información	Amenazas, controles técnicos e incidentes.
Proveedor tecnológico	Cumple contrato, aporta documentación, pruebas y soporte.
Personal revisor	Confirma, corrige o rechaza la recomendación.

Los roles exactos deben ajustarse a la estructura y competencias vigentes del Ayuntamiento.

7.2. Condiciones contractuales

El pliego debería exigir documentación del modelo, finalidad y límites; localización y transferencias de datos; lista de subencargados; prohibición de reutilización no autorizada; gestión de cambios; derecho de auditoría; niveles de servicio; interoperabilidad; exportación y eliminación de datos; respuesta a incidentes; pruebas de seguridad; y colaboración para atender derechos de las personas.

Capítulo 8

Hoja de ruta de implantación

Fase	Entregable	Actividades
0–2 semanas	Definición y gobernanza	Propósito, límites, responsables, mapa de proceso y criterio de éxito.
3–4 semanas	Evaluación previa	Clasificación AI Act, análisis RGPD, evaluación inicial de riesgos y proveedor.
5–7 semanas	Prototipo con datos sintéticos	Catálogo de categorías, interfaz de revisión, logs y pruebas funcionales.
8–10 semanas	Prueba controlada	Evaluación con conjunto validado, pruebas de privacidad, seguridad y accesibilidad.
11–12 semanas	Decisión de continuidad	Informe de resultados, brechas, costes, aceptación formal y plan de mejora.
Posterior	Operación supervisada	Monitorización, auditorías, formación, re-evaluación tras cambios e incidentes.

8.1. Condiciones para detener o pausar

Pausar el piloto si se detectan derivaciones sistemáticamente incorrectas, datos personales enviados a un proveedor no autorizado, resultados discriminatorios, falta de trazabilidad, fallos de supervisión humana, vulnerabilidades críticas o cambios de finalidad que invaliden la evaluación original.

Capítulo 9

Conclusiones

El caso demuestra cómo plantear un uso municipal de IA centrado en apoyo al personal, no en automatización de decisiones administrativas. La viabilidad depende menos de la elección aislada del modelo que de la calidad del proceso, el catálogo de destino, la gestión de datos, la revisión humana y la capacidad de auditar resultados. La puesta en producción requiere una clasificación regulatoria documentada, análisis de protección de datos, seguridad, contratación y evaluación empírica del piloto.

Apéndice A

Ejemplos de datos sintéticos

El archivo `datos/ejemplos_sinteticos.csv` contiene ocho ejemplos ficticios, incluidas entradas que deben escalarse a revisión humana. No contiene datos reales de residentes ni representa el histórico municipal.

Apéndice B

Checklist de aprobación

- ☐ Propósito y límites aprobados por la unidad propietaria.
- ☐ Clasificación AI Act documentada con versión normativa vigente.
- ☐ Registro del tratamiento y base jurídica revisados.
- ☐ Decisión sobre EIPD y evaluación de derechos fundamentales documentada.
- ☐ Evaluación de proveedor, seguridad y contratación completada.
- ☐ Datos de prueba autorizados, minimizados y representativos.
- ☐ Métricas, umbrales y criterios de parada acordados antes de probar.
- ☐ Supervisión humana y mecanismo de reclamación definidos.
- ☐ Transparencia y formación de usuarios preparadas.
- ☐ Plan de monitorización, incidentes y revisión periódica aprobado.

Bibliografía

- [1] Ayuntamiento de Madrid. *La Inteligencia Artificial en Madrid Capital Digital*. <https://www.madrid.es/portales/munimadrid/es/Inicio/El-Ayuntamiento/Transformacion-Digital-/Inteligencia-Artificial/La-Inteligencia-Artificial-en-Madrid-Capital-Digital-Porque-lo-digital-es-capital/>
- [2] Ayuntamiento de Madrid. *Gobierno de la IA*. <https://www.madrid.es/portales/munimadrid/es/Inicio/El-Ayuntamiento/Transformacion-Digital-/Inteligencia-Artificial/Gobierno-de-la-IA/>
- [3] Unión Europea. *Reglamento (UE) 2024/1689, texto consolidado*. <https://eur-lex.europa.eu/legal-content/ES/TXT/HTML/?uri=CELEX:02024R1689-20260727>
- [4] Unión Europea. *Reglamento (UE) 2026/1744*. <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX:32026R1744>
- [5] Unión Europea. *Reglamento (UE) 2016/679 (RGPD)*. <https://eur-lex.europa.eu/legal-content/ES/ALL/?uri=celex:32016R0679>
- [6] ISO. *ISO/IEC 42001:2023 — Artificial intelligence management system*. <https://www.iso.org/standard/81230.html>
- [7] ISO. *ISO/IEC 23894:2023 — Guidance on risk management*. <https://www.iso.org/standard/77304.html>
- [8] ISO. *ISO/IEC 42005:2025 — AI system impact assessment*. <https://www.iso.org/standard/42005>