

Introducción a la Estadística Aplicada a la Inteligencia Artificial

**Fundamentos estadísticos para datos, Machine Learning y
evaluación de modelos**

José Manuel Aroca Fernández

2026

Presentación

La estadística constituye uno de los fundamentos matemáticos de la Inteligencia Artificial moderna. Este material introduce los conceptos necesarios para explorar datos, construir modelos, evaluar predicciones y cuantificar incertidumbre.

El documento está orientado a estudiantes y profesionales que comienzan a trabajar con Inteligencia Artificial, Machine Learning y análisis de datos. Se combinan conceptos matemáticos con ejemplos aplicados y fragmentos de Python utilizando herramientas habituales del ecosistema científico.

Glosario de términos y símbolos

Este glosario se presenta al comienzo del documento para facilitar la lectura. Se distinguen el vocabulario específico de estadística y Machine Learning y los símbolos matemáticos utilizados en las fórmulas.

A. Vocabulario específico

Aprendizaje automático (Machine Learning)

Técnicas que permiten aprender patrones a partir de datos para realizar tareas como predicción, clasificación o agrupamiento.

Aprendizaje supervisado

Aprendizaje a partir de observaciones que incluyen una variable objetivo conocida.

Aprendizaje no supervisado

Análisis de estructuras de datos sin necesidad de disponer de una variable objetivo.

Bias / sesgo

Componente sistemática del error asociada a una representación o modelo demasiado restrictivo.

Bootstrap

Remuestreo con reemplazamiento para estudiar la variabilidad de estimadores.

Covarianza

Medida de cómo dos variables varían conjuntamente.

Correlación

Medida normalizada de asociación lineal entre variables.

Data leakage / fuga de información

Uso indebido de información que no debería estar disponible durante entrenamiento o evaluación.

Data drift / deriva de datos

Cambio de la distribución de los datos entre momentos, regiones, sensores o contextos.

Desviación típica

Raíz cuadrada de la varianza, expresada en las unidades originales.

Distribución

Forma en que se reparten los valores de una variable.

Error

Diferencia entre un valor observado y una predicción.

Feature / característica

Variable utilizada como entrada de un modelo.

Feature engineering

Construcción o transformación de variables para mejorar la representación del problema.

Hiperparámetro Parámetro de configuración elegido para controlar el entrenamiento y no estimado directamente como parámetro del modelo.

Intervalo de confianza

Rango obtenido mediante un procedimiento estadístico para cuantificar incertidumbre sobre un parámetro.

MAE Error absoluto medio.

Mediana Valor central de los datos ordenados.

Modelo Representación matemática o computacional utilizada para explicar, estimar o predecir.

Outlier / valor atípico

Observación alejada del comportamiento predominante; debe investigarse antes de eliminarse.

PCA Análisis de Componentes Principales; técnica de reducción de dimensionalidad basada en direcciones de máxima varianza.

Pipeline Secuencia reproducible de transformaciones y un modelo.

Población Conjunto completo sobre el que se desea obtener conclusiones.

RMSE Raíz del error cuadrático medio.

Residuo Diferencia entre el valor observado y el valor predicho.

Regularización Restricción de la complejidad del modelo para reducir el riesgo de sobreajuste.

Sesgo-varianza Compromiso entre error sistemático y variabilidad del modelo ante diferentes muestras de entrenamiento.

Sobreajuste / overfitting

Adaptación excesiva a entrenamiento con peor generalización.

Subajuste / underfitting

Modelo demasiado simple para representar adecuadamente la estructura de los datos.

Train/Test split División entre datos de entrenamiento y datos reservados para evaluación.

Validación cruzada

Procedimiento basado en varias particiones para estimar el rendimiento.

Variable objetivo / target

Variable que el modelo intenta predecir.

Varianza Medida de dispersión basada en desviaciones cuadráticas respecto a la media.

Varianza explicada

Proporción de variabilidad representada por una componente o modelo, según el contexto.

B. Símbolos y notación matemática

Símbolo	Nombre	Descripción
n	Tamaño muestral	Número de observaciones.
N	Tamaño poblacional	Número de elementos de la población.
x_i	Observación	Valor i -ésimo de una variable.
$\bar{x}$	Media muestral	Promedio de las observaciones.
μ	Media poblacional	Media de la población.
s^2	Varianza muestral	Estimador de la varianza poblacional.
σ^2	Varianza poblacional	Varianza de una población.
s	Desviación típica muestral	Raíz cuadrada de s^2 .
σ	Desviación típica poblacional	Raíz cuadrada de σ^2 .
Q_1	Primer cuartil	Percentil 25.
Q_2	Segundo cuartil	Mediana o percentil 50.
Q_3	Tercer cuartil	Percentil 75.
IQR	Rango intercuartílico	$Q_3 - Q_1$.
X	Variable / matriz de datos	Variable o conjunto de características, según el contexto.
Y	Variable objetivo	Variable que se desea explicar o predecir.
$\hat{Y}$	Predicción	Valor estimado por el modelo.
$\hat{y}_i$	Predicción i	Predicción de la observación i .
e_i	Residuo	$e_i = y_i - \hat{y}_i$.
$\text{Cov}(X, Y)$	Covarianza	Variación conjunta de X e Y .
r	Correlación de Pearson	Asociación lineal normalizada.
Σ	Matriz de covarianzas	Matriz de varianzas y covarianzas.
λ	Autovalor	Valor asociado a una dirección principal.
v	Autovector	Dirección asociada a un autovalor.
PC_i	Componente principal	Nueva variable obtenida mediante PCA.
EVR_i	Varianza explicada relativa	Proporción de varianza explicada.
$\mathbb{E}[X]$	Esperanza	Valor medio teórico.
$P(A)$	Probabilidad	Probabilidad del suceso A .
$P(A B)$	Probabilidad condicionada	Probabilidad de A dado B .
α	Nivel de significación	Parámetro usado en contrastes estadísticos.
$1 - \alpha$	Nivel de confianza	Nivel nominal asociado a un intervalo.
β_0	Intercepto	Término independiente de un modelo lineal.
β_j	Coefficiente	Peso asociado a X_j .
ϵ	Error aleatorio	Componente no explicada por el modelo.
$\mathcal{L}$	Función de pérdida	Función que cuantifica el error.
K	Número de folds	Número de particiones en validación cruzada.

C. Fórmulas de referencia

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

$$e_i = y_i - \hat{y}_i, \quad RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}.$$

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

$$\Sigma v = \lambda v.$$

La última expresión resume la relación fundamental entre la matriz de covarianzas y las componentes principales de PCA.

Índice general

Presentación	i
Glosario de términos y símbolos	ii
1. Introducción a la estadística y la Inteligencia Artificial	1
1.1. Objetivos de aprendizaje	1
1.2. Estadística e Inteligencia Artificial	2
1.3. Población y muestra	2
1.4. Tipos de variables	3
2. Estadística descriptiva	4
2.1. Tipos de variables	4
2.2. Media	5
2.3. Mediana y moda	6
2.4. Varianza y desviación típica	7
2.5. Percentiles y rango intercuartílico	7
2.6. Ejemplo completo de estadística descriptiva	8
2.7. Interpretación de la estadística descriptiva en IA	9
2.8. Ejemplo con Python	13
2.9. Ejercicios propuestos	13
3. Probabilidad y distribuciones	16
3.1. Probabilidad	16
3.2. Distribución normal	16
3.3. Otras distribuciones	17
4. Correlación, covarianza, varianza y regresión	18
4.1. Varianza: concepto e interpretación	18
4.2. Por qué aparece $n - 1$ en la varianza muestral	19
4.3. Desviación típica frente a varianza	19
4.4. Varianza y Machine Learning	20
4.4.1. Ejemplo 1. Dataset correctamente preparado	20
4.4.2. Ejemplo 2. Dataset con un valor atípico que distorsiona la varianza	21
4.4.3. Ejemplo 3. Varianza diferente entre entrenamiento y prueba	22
4.4.4. Ejemplo 4. Modelo con elevada varianza: sobreajuste	22
4.4.5. Comparación de los cuatro escenarios	23
4.5. Covarianza	24
4.6. Limitación de la covarianza	25
4.7. Correlación de Pearson	25
4.8. Ejemplo detallado de correlación positiva	25
4.9. Ejemplo detallado de correlación negativa	26
4.10. Correlación cercana a cero	26

4.11. Correlación y causalidad	26
4.12. Correlación y selección de variables	27
4.13. Varianza, covarianza y matriz de covarianzas	27
4.13.1. Ejemplo completo con tres variables	27
4.13.2. Interpretación en Machine Learning	28
4.14. Relación con PCA	29
4.14.1. Ejemplo numérico completo paso a paso	29
4.14.2. Ejemplo de implementación con Python	31
4.14.3. PCA dentro de un modelo de Machine Learning	32
4.14.4. Interpretación para teledetección	32
4.15. Correlación en datos de IA: precauciones	33
4.16. Ejemplo con Python	33
4.17. Ejercicios propuestos	34
5. Evaluación de modelos de Machine Learning	37
5.1. Residuos	37
5.2. MAE	38
5.3. MSE y RMSE	38
5.4. Coeficiente de determinación	38
6. Sesgo, varianza y sobreajuste	39
6.1. Objetivos del capítulo	39
6.2. Generalización	39
6.3. Sesgo	40
6.4. Varianza del modelo	40
6.5. Descomposición sesgo-varianza	40
6.6. Subajuste y sobreajuste	40
6.6.1. Subajuste	40
6.6.2. Sobreajuste	41
6.7. Ejemplo comparativo	41
6.8. Complejidad del modelo	41
6.9. Curvas de aprendizaje	41
6.10. Regularización	42
6.11. Validación cruzada y estabilidad	42
6.12. Estrategias de control del sobreajuste	42
6.13. Ejemplo práctico con Python	43
6.14. Varianza de los datos frente a varianza del modelo	44
6.15. Checklist de diagnóstico	44
6.16. Resumen	44
7. Muestreo y validación cruzada	45
7.1. División de los datos	45
7.2. k -fold cross-validation	45
8. Inferencia estadística e incertidumbre	47
8.1. Intervalos de confianza	47
8.2. Pruebas de hipótesis	47
8.3. Incertidumbre en predicciones	48

9. Preprocesamiento estadístico	49
9.1. Estandarización	49
9.2. Escalado Min-Max	49
9.3. Valores atípicos	50
10. Ejemplo práctico con Python	51
11. Caso aplicado: predicción de una variable ambiental	53
12. Ejercicios	55
12.1. Ejercicio 1: estadística descriptiva	55
12.2. Ejercicio 2: métricas	55
12.3. Ejercicio 3: sobreajuste	56
12.4. Ejercicio 4: distribuciones	56
12.5. Ejercicio 5: comparación de modelos	56
Resumen de conceptos	57
Índice de fórmulas	58

Índice de cuadros

1.1. Relación entre estadística e Inteligencia Artificial.	2
2.1. Tipos de variables y ejemplos aplicados a Inteligencia Artificial.	5
4.1. Interpretación de la varianza en cuatro escenarios de Machine Learning.	23
4.2. Datos de ejemplo para varianza, covarianza y PCA	27
6.1. Tres comportamientos posibles	41
12.1. Resumen de conceptos fundamentales.	57

Capítulo 1

Introducción a la estadística y la Inteligencia Artificial

Este capítulo establece el marco conceptual del curso. Se explica por qué la estadística es una pieza fundamental de la Inteligencia Artificial y cómo se relaciona con las distintas etapas de un proyecto de Machine Learning, desde la exploración inicial hasta la evaluación y comunicación de resultados.

CAPÍTULO 1

Introducción a la estadística y la Inteligencia Artificial

Datos → Estadística → Modelo → Evaluación → Decisión




Figura 1.1: Introducción visual: Introducción a la estadística y la Inteligencia Artificial.

1.1. Objetivos de aprendizaje

Al finalizar este material el estudiante será capaz de:

1. distinguir población, muestra y tipos de variables;
2. calcular e interpretar medidas descriptivas;
3. analizar distribuciones de datos;
4. comprender probabilidad y probabilidad condicionada;

5. interpretar correlación y covarianza;
6. comprender modelos básicos de regresión;
7. calcular métricas de evaluación de modelos de IA;
8. comprender sesgo, varianza y sobreajuste;
9. utilizar validación cruzada;
10. interpretar incertidumbre y residuos;
11. identificar problemas de fuga de información;
12. aplicar estos conceptos mediante Python.

1.2. Estadística e Inteligencia Artificial

La estadística interviene en prácticamente todas las fases de un proyecto de Inteligencia Artificial:

Etapa	Aplicación estadística
Exploración	Media, mediana, dispersión, percentiles y distribuciones.
Preprocesamiento	Valores ausentes, atípicos y transformaciones.
Selección de variables	Correlación, dependencia y redundancia.
Entrenamiento	Estimación de parámetros y minimización del error.
Validación	Muestreo, validación cruzada y estimación del rendimiento.
Evaluación	MAE, RMSE, R^2 , precisión, recall y F1.
Incertidumbre	Intervalos, distribución de errores y predicción probabilística.

Cuadro 1.1: Relación entre estadística e Inteligencia Artificial.

Concepto clave

Un modelo de IA no debe analizarse únicamente por sus predicciones. También es necesario estudiar los datos utilizados, el procedimiento de validación, la distribución de los errores y la incertidumbre asociada.

1.3. Población y muestra

La **población** representa el conjunto de elementos sobre el que se desea obtener conclusiones. Una **muestra** es el subconjunto utilizado para realizar el estudio.

Si se desea construir un modelo para estimar una propiedad del suelo de una región, la población puede estar formada por todos los puntos de interés y la muestra por las observaciones disponibles para el entrenamiento y evaluación.

La representatividad de la muestra es esencial para la generalización.

1.4. Tipos de variables

Las variables pueden clasificarse en:

- **Cualitativas:** representan categorías.
- **Ordinales:** las categorías poseen un orden.
- **Cuantitativas discretas:** toman valores contables.
- **Cuantitativas continuas:** pueden tomar valores en un intervalo.

Capítulo 2

Estadística descriptiva

Antes de entrenar un modelo de Inteligencia Artificial es necesario comprender los datos con los que se trabaja. La estadística descriptiva proporciona herramientas para resumir, visualizar y detectar características importantes de un conjunto de datos. En este capítulo se estudian las medidas de tendencia central, dispersión y posición, acompañadas de ejemplos relacionados con problemas habituales de Inteligencia Artificial.



Figura 2.1: Introducción visual: Estadística descriptiva.

2.1. Tipos de variables

Una de las primeras tareas de cualquier análisis estadístico consiste en identificar correctamente el tipo de variable. Esta clasificación condiciona las operaciones matemáticas, las visualizaciones y los métodos estadísticos que pueden aplicarse.

Tipo	Definición	Ejemplo	Uso en IA
Cualitativa nominal	Categorías sin orden	Tipo de suelo: arcilloso, arenoso, limoso	Clasificación, codificación categórica
Cualitativa ordinal	Categorías con un orden	Riesgo: bajo, medio, alto	Clasificación ordinal
Cuantitativa discreta	Valores numéricos contables	Número de árboles: 0, 1, 2, 3	Conteos y variables de frecuencia
Cuantitativa continua	Valores numéricos en un intervalo	Temperatura: 21.7 °C	Regresión y predicción
Binaria	Dos categorías posibles	Nube: sí/no	Clasificación binaria

Cuadro 2.1: Tipos de variables y ejemplos aplicados a Inteligencia Artificial.

Ejemplo

En un conjunto de datos agrícola podemos tener:

- `tipo_suelo`: variable cualitativa nominal;
- `nivel_riesgo`: variable cualitativa ordinal;
- `numero_muestras`: variable cuantitativa discreta;
- `temperatura`: variable cuantitativa continua;
- `nube`: variable binaria;
- `SOC`: variable cuantitativa continua utilizada como variable objetivo de un modelo de regresión.

Atención

Una variable codificada numéricamente no necesariamente es cuantitativa. Por ejemplo, asignar los valores 1, 2 y 3 a tres tipos de suelo no significa que puedan realizarse operaciones aritméticas con dichas categorías.

2.2. Media

La media aritmética resume un conjunto de valores mediante su promedio:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Ejemplo

Supongamos que las concentraciones de carbono orgánico del suelo medidas en cinco muestras son:

18, 21, 19, 24, 23.

La media es:

$$\bar{x} = \frac{18 + 21 + 19 + 24 + 23}{5} = 21.$$

Por tanto, el contenido medio observado es de 21 unidades de la variable medida.

Ejemplo

Consideremos ahora los tiempos de ejecución, en segundos, de un algoritmo:

$$1.2, \quad 1.4, \quad 1.1, \quad 1.3, \quad 1.0.$$

La media es:

$$\bar{x} = \frac{1.2 + 1.4 + 1.1 + 1.3 + 1.0}{5} = 1.2.$$

La media proporciona una primera estimación del tiempo de ejecución típico.

2.3. Mediana y moda

La **mediana** es el valor que ocupa la posición central cuando las observaciones están ordenadas. La **moda** es el valor que aparece con mayor frecuencia.

Para un número impar de observaciones, la posición de la mediana es:

$$\frac{n + 1}{2}.$$

Ejemplo

Consideremos los valores:

$$10, \quad 12, \quad 14, \quad 16, \quad 18.$$

La mediana es:

$$Me = 14.$$

La mitad de las observaciones es menor o igual que 14 y la otra mitad es mayor o igual que 14.

Ejemplo

Supongamos ahora los tiempos de respuesta:

$$10, \quad 11, \quad 11, \quad 12, \quad 13, \quad 50.$$

La media es:

$$\bar{x} = 17.83,$$

mientras que la mediana es:

$$Me = \frac{11 + 12}{2} = 11.5.$$

El valor 50 modifica considerablemente la media, pero tiene un efecto mucho menor sobre la mediana. Por este motivo, la mediana puede ser una medida de posición más representativa

cuando existen valores extremos.

Ejemplo

En una variable categórica como

bosque, cultivo, cultivo, pastizal, cultivo,

la moda es *cultivo*. La media y la mediana no tienen sentido para esta variable nominal.

2.4. Varianza y desviación típica

La varianza mide la dispersión de las observaciones respecto de la media.

Para una muestra:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s = \sqrt{s^2}.$$

La desviación típica tiene las mismas unidades que la variable original.

Ejemplo

Consideremos dos conjuntos de mediciones:

$$A = \{9, 10, 10, 11, 10\}$$

y

$$B = \{5, 8, 10, 12, 15\}.$$

Ambos conjuntos tienen una media próxima a 10, pero las observaciones del conjunto *B* están más dispersas. Por tanto, su desviación típica es mayor.

Esto muestra por qué dos variables pueden tener la misma media y presentar un comportamiento muy diferente.

Ejemplo

Supongamos dos modelos de IA que producen errores absolutos con media similar. Si uno presenta una desviación típica de los errores mucho mayor, sus resultados son menos homogéneos y conviene analizar la distribución completa de los errores, no solamente su media.

2.5. Percentiles y rango intercuartílico

Los percentiles permiten conocer la posición relativa de una observación dentro de una distribución.

Los cuartiles principales son:

$$Q_1 = P_{25}, \quad Q_2 = P_{50}, \quad Q_3 = P_{75}.$$

El rango intercuartílico es:

$$IQR = Q_3 - Q_1.$$

Ejemplo

Si los tiempos de respuesta de una aplicación presentan:

$$Q_1 = 120 \text{ ms}, \quad Q_2 = 180 \text{ ms}, \quad Q_3 = 250 \text{ ms},$$

entonces:

$$IQR = 250 - 120 = 130 \text{ ms}.$$

El 50 % central de las observaciones se encuentra entre 120 ms y 250 ms.

Ejemplo

En un modelo de predicción podemos estudiar los percentiles del error absoluto. Si el percentil 90 es de 25 unidades, significa que aproximadamente el 90 % de los errores absolutos observados no supera 25 unidades, según el procedimiento de cálculo utilizado.

El IQR también puede emplearse para identificar posibles valores atípicos. Una regla habitual consiste en considerar como candidatos a atípicos los valores que cumplen:

$$x < Q_1 - 1.5IQR$$

o

$$x > Q_3 + 1.5IQR.$$

Atención

Esta regla identifica observaciones potencialmente atípicas, pero no demuestra que sean errores. Una observación extrema puede ser perfectamente válida y representar una situación real importante.

2.6. Ejemplo completo de estadística descriptiva

Consideremos las siguientes mediciones de una variable ambiental:

$$12, 15, 18, 20, 20, 22, 25, 30.$$

Podemos resumirlas mediante:

- media;
- mediana;
- moda;
- mínimo y máximo;
- rango;
- varianza;
- desviación típica;

- cuartiles.

La media es:

$$\bar{x} = \frac{12 + 15 + 18 + 20 + 20 + 22 + 25 + 30}{8} = 20.25.$$

La mediana es:

$$Me = \frac{20 + 20}{2} = 20.$$

La moda es:

$$Mo = 20.$$

El rango es:

$$R = 30 - 12 = 18.$$

Este ejemplo permite observar que diferentes medidas proporcionan información complementaria. La media resume el centro, la mediana aporta una posición robusta, la moda identifica el valor más frecuente y las medidas de dispersión describen cuánto se separan las observaciones.

2.7. Interpretación de la estadística descriptiva en IA

La estadística descriptiva no constituye una etapa independiente del aprendizaje automático. Sus resultados ayudan a decidir cómo representar los datos, qué transformaciones aplicar, qué problemas de calidad deben investigarse y qué métricas pueden ser apropiadas.

En un proyecto de Inteligencia Artificial conviene analizar, como mínimo:

- el tamaño de la muestra;
- el rango de cada variable;
- las medidas de tendencia central;
- la dispersión;
- los percentiles;
- los valores ausentes;
- los posibles valores atípicos;
- la distribución de la variable objetivo;
- las diferencias entre grupos;
- las relaciones entre variables.

Ejemplo

Ejemplo 1. Variables con escalas muy diferentes.

Supongamos un conjunto de datos con:

$$\text{edad} \in [18, 80]$$

y:

salario $\in [1000, 120000]$.

Las dos variables contienen información numérica, pero sus escalas son muy diferentes. Algunos algoritmos pueden beneficiarse de una estandarización o normalización. La estadística descriptiva permite detectar este problema antes del entrenamiento.

Ejemplo

Ejemplo 2. Variable objetivo con fuerte asimetría.

Supongamos que queremos predecir el precio de viviendas. La mayoría de las viviendas tienen precios entre 100 000 y 300 000 euros, pero existen unas pocas viviendas de más de 2 000 000 euros.

La media puede quedar muy por encima de la mediana. Esta diferencia indica una posible asimetría positiva y recomienda estudiar la distribución antes de seleccionar transformaciones y métricas.

Ejemplo

Ejemplo 3. Desbalance entre clases.

Supongamos un problema de detección de fraude con:

9500 operaciones normales

y:

500 operaciones fraudulentas.

La clase minoritaria representa solamente el 5 % de las observaciones. Un modelo podría obtener una exactitud aparentemente elevada prediciendo la clase mayoritaria en la mayoría de los casos.

La estadística descriptiva permite detectar este desbalance antes de evaluar el modelo.

Ejemplo

Ejemplo 4. Valores ausentes.

Un conjunto de datos contiene 10 000 observaciones, pero una variable meteorológica presenta 2 300 valores ausentes.

La proporción de valores ausentes es:

$$\frac{2300}{10000} \times 100 = 23 \%$$

Este resultado es suficientemente importante como para investigar por qué faltan los datos y decidir si se imputan, se elimina la variable o se utiliza un modelo capaz de trabajar con valores ausentes.

Ejemplo

Ejemplo 5. Valores atípicos en datos de sensores.

Un sensor registra:

18.2, 18.4, 18.1, 18.3, 18.5, 97.4.

La observación 97.4 es muy diferente del resto. Puede deberse a un error de medida, una

avería, una interferencia o a un fenómeno real.

Antes de eliminarla debe investigarse su origen. En IA, eliminar automáticamente todos los valores extremos puede eliminar precisamente los casos raros que el modelo debe aprender a detectar.

Ejemplo

Ejemplo 6. Distribución de una variable objetivo.

En un problema de regresión de carbono orgánico del suelo, imaginemos:

$$Q_1 = 12, \quad Me = 18, \quad Q_3 = 27.$$

Si además existen observaciones superiores a 100, conviene estudiar la distribución y la posible presencia de una cola derecha.

Podrían considerarse transformaciones, modelos robustos o métricas complementarias, pero la decisión debe basarse también en el significado científico de la variable.

Ejemplo

Ejemplo 7. Comparación de grupos.

Supongamos que se analizan dos tipos de suelo:

	Media SOC	Desviación típica
Suelo A	24.5	4.2
Suelo B	31.8	12.7

El segundo grupo presenta una media superior, pero también una variabilidad mucho mayor. Por tanto, comparar únicamente las medias ocultaría una parte importante de la estructura de los datos.

Ejemplo

Ejemplo 8. Diferencias entre entrenamiento y producción.

Un modelo se entrenó con imágenes cuya reflectancia presenta:

$$\mu_{\text{train}} = 0.31, \quad \sigma_{\text{train}} = 0.08.$$

Meses después, los datos de producción presentan:

$$\mu_{\text{prod}} = 0.39, \quad \sigma_{\text{prod}} = 0.14.$$

Las diferencias sugieren un posible cambio en la distribución de entrada. Antes de atribuir una reducción del rendimiento al modelo, conviene investigar este posible *data drift*.

Ejemplo

Ejemplo 9. Análisis de errores de un modelo.

Supongamos que un modelo de regresión produce errores absolutos con:

$$MAE = 4.8$$

pero el percentil 95 del error absoluto es:

$$P_{95} = 15.7.$$

La media proporciona una medida global, mientras que el percentil 95 indica que existe una parte de las predicciones con errores mucho mayores. Para una aplicación crítica, esta información puede ser tan relevante como el MAE.

Ejemplo

Ejemplo 10. Variables casi constantes.

Una variable presenta:

$$\mu = 0.501$$

y:

$$\sigma = 0.0003.$$

Si prácticamente todas las observaciones son iguales, la variable puede aportar poca información predictiva. Su eliminación o tratamiento debe decidirse mediante análisis adicional y validación del modelo, no únicamente a partir de una regla automática.

Ejemplo

Ejemplo 11. Estadística descriptiva por localización.

En datos geográficos, dos regiones pueden presentar la misma media de una variable ambiental:

$$\bar{x}_A = \bar{x}_B = 25.$$

Sin embargo, la región A puede tener valores concentrados alrededor de 25 mientras que la región B puede combinar valores muy bajos y muy altos.

Esto demuestra que la media no contiene toda la información espacial. En datos geográficos es necesario estudiar también distribución, variabilidad y dependencia espacial.

Ejemplo

Ejemplo 12. Interpretación conjunta.

Supongamos:

$$\bar{x} = 50, \quad Me = 42, \quad s = 20, \quad Q_1 = 35, \quad Q_3 = 55.$$

La diferencia entre media y mediana sugiere una posible asimetría. La desviación típica indica una dispersión considerable y el IQR:

$$IQR = 55 - 35 = 20.$$

Por tanto, la interpretación adecuada no consiste en afirmar simplemente que “el valor típico es 50”, sino en estudiar conjuntamente las medidas de posición, dispersión y forma de la distribución.

Concepto clave

En Inteligencia Artificial, la estadística descriptiva sirve como mecanismo de diagnóstico. Permite detectar problemas antes del entrenamiento y proporciona contexto para interpretar las métricas del modelo.

2.8. Ejemplo con Python

Las medidas anteriores pueden calcularse directamente con **pandas**:

```
1 import pandas as pd
2
3 datos = pd.Series(
4     [12, 15, 18, 20, 20, 22, 25, 30],
5     name="variable"
6 )
7
8 print("Media:", datos.mean())
9 print("Mediana:", datos.median())
10 print("Moda:", datos.mode().tolist())
11 print("Desviacion tipica:", datos.std())
12 print("Minimo:", datos.min())
13 print("Maximo:", datos.max())
14
15 print("Cuartiles:")
16 print(datos.quantile([0.25, 0.50, 0.75]))
```

También podemos obtener un resumen completo mediante:

```
1 print(datos.describe())
```

2.9. Ejercicios propuestos

Ejercicio 1. Tipos de variables

Clasifica las siguientes variables:

1. número de muestras de suelo tomadas en una parcela;
2. tipo de cultivo;
3. temperatura del suelo;
4. nivel de riesgo: bajo, medio o alto;
5. presencia de nubes: sí/no.

Para cada variable indica si es cualitativa nominal, cualitativa ordinal, cuantitativa discreta, cuantitativa continua o binaria.

Ejercicio 2. Medidas de tendencia central

Dados los valores:

14, 16, 16, 18, 20, 21, 25, 30,

calcula:

1. media;
2. mediana;
3. moda;
4. rango.

Explica qué medida utilizarías para representar el centro de los datos si apareciese posteriormente una observación extrema.

Ejercicio 3. Dispersión

Considera:

$$A = \{10, 10, 11, 10, 9, 10\}$$

y

$$B = \{3, 7, 10, 13, 17, 10\}.$$

Calcula la media y la desviación típica de ambos conjuntos. Explica por qué comparar solamente las medias no permite conocer completamente el comportamiento de los datos.

Ejercicio 4. Percentiles y valores atípicos

Dado el conjunto:

$$5, 7, 8, 10, 11, 12, 13, 15, 18, 40,$$

calcula Q_1 , Q_2 , Q_3 e IQR utilizando un método coherente de cálculo de cuantiles.

Después determina los límites:

$$Q_1 - 1.5IQR$$

y

$$Q_3 + 1.5IQR.$$

Indica qué observaciones serían candidatas a valores atípicos según esta regla y explica por qué el resultado debe interpretarse con cautela.

Ejercicio 5. Aplicación a Inteligencia Artificial

Un modelo de Machine Learning produce los siguientes errores absolutos:

$$3, 4, 5, 5, 6, 7, 8, 9, 10, 25.$$

Realiza un análisis descriptivo que incluya:

1. media;
2. mediana;
3. desviación típica;
4. mínimo y máximo;
5. cuartiles;

6. IQR.

Finalmente, responde:

- ¿Qué efecto tiene el error 25 sobre la media?
- ¿Qué información aporta la mediana?
- ¿Qué métrica adicional utilizarías para evaluar el modelo?
- ¿Por qué no sería suficiente informar únicamente de la media?

Capítulo 3


Probabilidad y distribuciones

La Inteligencia Artificial trabaja con información incompleta y resultados inciertos. En este capítulo se introducen la probabilidad, la probabilidad condicionada, el teorema de Bayes y las distribuciones de probabilidad que sirven de base para numerosos métodos estadísticos y de aprendizaje automático.

CAPÍTULO 3

Probabilidad y distribuciones

P(X) · condicionada · Bayes · distribuciones



$P(A|B)$

$P(A \cap B)$

$P(B)$

Figura 3.1: Introducción visual: Probabilidad y distribuciones.

3.1. Probabilidad

Para un evento A :

$$0 \leq P(A) \leq 1.$$

La probabilidad condicionada es $P(A | B) = \frac{P(A \cap B)}{P(B)}$.

El teorema de Bayes establece: $P(A | B) = \frac{P(B|A)P(A)}{P(B)}$.

3.2. Distribución normal

La densidad normal es

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

La normal aparece frecuentemente como modelo de referencia para errores, pero los datos reales no tienen por qué seguir esta distribución.

3.3. Otras distribuciones

En función del problema pueden ser relevantes:

- Bernoulli;
- binomial;
- Poisson;
- uniforme;
- exponencial;
- t de Student;
- chi-cuadrado;
- distribuciones empíricas.

Capítulo 4

Correlación, covarianza, varianza y regresión

Este capítulo desarrolla con mayor profundidad las relaciones estadísticas entre variables. La varianza permite cuantificar la dispersión de una variable, la covarianza describe cómo varían conjuntamente dos variables y la correlación normaliza esa relación para facilitar su interpretación. Estos conceptos son fundamentales en análisis exploratorio, selección de variables, reducción de dimensionalidad y construcción de modelos de Inteligencia Artificial.




Figura 4.1: Introducción visual: Correlación, covarianza, varianza y regresión.

4.1. Varianza: concepto e interpretación

La varianza cuantifica cuánto se separan las observaciones de su media.

Para una población:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2.$$

Para una muestra:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

El cuadrado de las desviaciones evita que los valores positivos y negativos se compensen.

Ejemplo

Consideremos:

$$X = \{2, 4, 4, 6\}.$$

La media es:

$$\bar{x} = 4.$$

Las desviaciones respecto a la media son:

$$-2, 0, 0, 2.$$

Sus cuadrados son:

$$4, 0, 0, 4.$$

La suma de cuadrados es:

$$8.$$

La varianza poblacional sería:

$$\sigma^2 = \frac{8}{4} = 2.$$

Si estos cuatro valores constituyen una muestra:

$$s^2 = \frac{8}{3} \approx 2.67.$$

4.2. Por qué aparece $n - 1$ en la varianza muestral

Cuando se estima la varianza de una población a partir de una muestra, la media poblacional μ es desconocida y se sustituye por la media muestral $\bar{x}$. La corrección $n - 1$ está relacionada con los grados de libertad y proporciona un estimador insesgado de la varianza poblacional bajo las condiciones habituales.

La diferencia puede parecer pequeña cuando n es grande, pero es importante comprender qué cantidad se está calculando:

- σ^2 : varianza de la población;
- s^2 : estimación muestral de la varianza.

4.3. Desviación típica frente a varianza

La varianza está expresada en unidades al cuadrado:

$$[\text{variable}]^2.$$

La desviación típica vuelve a las unidades originales:

$$s = \sqrt{s^2}.$$

Ejemplo

Si una variable representa temperatura en grados Celsius y:

$$s^2 = 25,$$

entonces:

$$s = 5 \text{ }^\circ\text{C}.$$

Para comunicar la variabilidad de la temperatura suele ser más intuitivo utilizar la desviación típica que la varianza.

4.4. Varianza y Machine Learning

La varianza tiene diferentes interpretaciones en un proyecto de Machine Learning. Puede describir la dispersión de una variable, la variabilidad de los errores, la estabilidad de las métricas entre particiones o uno de los componentes del compromiso entre sesgo y varianza.

Para comprender su utilidad es conveniente analizar tanto situaciones correctas como situaciones en las que los datos o el procedimiento de evaluación presentan problemas.

Concepto clave

Una varianza elevada no significa automáticamente que exista un error. Primero debe determinarse qué variable se está analizando, cuál es su unidad, qué población representa y si la variabilidad observada es esperable en el problema.

4.4.1. Ejemplo 1. Dataset correctamente preparado

Supongamos un problema de regresión para predecir una variable ambiental. Tenemos 1 000 observaciones y analizamos una variable de entrada X :

$$\mu_X = 50, \quad s_X = 8.$$

El histograma muestra una distribución razonablemente estable, no existen valores imposibles y las observaciones representan adecuadamente las condiciones que encontraremos durante la aplicación del modelo.

Además, dividimos los datos mediante un procedimiento apropiado:

$$80\% \text{ entrenamiento}, \quad 20\% \text{ prueba}.$$

El modelo produce los siguientes RMSE en cinco particiones de validación:

$$4.8, \quad 4.9, \quad 5.1, \quad 4.7, \quad 5.0.$$

La media es aproximadamente:

$$\overline{RMSE} = 4.90.$$

Los valores están relativamente próximos entre sí, lo que indica una variabilidad moderada de la métrica.

Ejemplo

En este escenario no hay un indicio evidente de un problema causado por la varianza. Los datos presentan una dispersión razonable y el rendimiento del modelo es relativamente estable entre particiones.

Esto no demuestra que el modelo sea correcto en todos los sentidos, pero sí proporciona un escenario coherente para continuar con el análisis de residuos, validación y generalización.

4.4.2. Ejemplo 2. Dataset con un valor atípico que distorsiona la varianza

Supongamos ahora que una variable presenta:

$$X = \{48, 49, 50, 51, 52, 49, 50, 51, 50, 500\}.$$

La mayoría de las observaciones están alrededor de 50, pero aparece una observación de 500. La media queda fuertemente afectada por esta observación:

$$\bar{x} = \frac{48 + 49 + 50 + 51 + 52 + 49 + 50 + 51 + 50 + 500}{10}.$$

El resultado es:

$$\bar{x} = 95.$$

La media ya no representa bien el comportamiento de las nueve observaciones normales. La varianza también aumenta considerablemente porque la distancia:

$$500 - 95$$

es muy grande y se eleva al cuadrado durante el cálculo de la varianza.

Atención

La existencia de una varianza elevada no significa que debamos eliminar automáticamente la observación 500. Primero debemos comprobar si se trata de un error de adquisición, una unidad incorrecta, una anomalía real o un caso excepcional que el modelo debe aprender.

Posibles actuaciones:

1. revisar el origen de la observación;
2. comprobar las unidades;
3. verificar el sensor o proceso de adquisición;
4. comparar con observaciones cercanas;
5. estudiar métricas robustas;
6. decidir su tratamiento utilizando conocimiento del dominio.

4.4.3. Ejemplo 3. Varianza diferente entre entrenamiento y prueba

Consideremos una variable utilizada por un modelo de IA.

En entrenamiento obtenemos:

$$\mu_{\text{train}} = 20, \quad \sigma_{\text{train}} = 3.$$

En prueba obtenemos:

$$\mu_{\text{test}} = 31, \quad \sigma_{\text{test}} = 9.$$

La distribución de prueba es claramente diferente.

El modelo ha aprendido principalmente a partir de observaciones concentradas alrededor de 20, mientras que durante la evaluación aparecen valores mucho más dispersos.

Ejemplo

Este caso puede ser indicativo de un cambio de distribución entre entrenamiento y prueba. Las causas pueden incluir:

- muestras procedentes de regiones diferentes;
- periodos temporales diferentes;
- sensores diferentes;
- cambios en las condiciones ambientales;
- un procedimiento de muestreo no representativo.

No sería adecuado atribuir automáticamente la pérdida de rendimiento a un problema intrínseco del algoritmo. Primero habría que investigar la diferencia entre las distribuciones.

Una herramienta útil consiste en comparar:

$$\mu_{\text{train}} \text{ frente a } \mu_{\text{test}}$$

y:

$$\sigma_{\text{train}} \text{ frente a } \sigma_{\text{test}},$$

pero también histogramas, percentiles y otras medidas de distribución.

4.4.4. Ejemplo 4. Modelo con elevada varianza: sobreajuste

Consideremos ahora un problema en el que entrenamos un modelo muy flexible.

Obtenemos:

$$R^2_{\text{train}} = 0.99$$

pero:

$$R^2_{\text{test}} = 0.48.$$

Además, al realizar cinco particiones de validación cruzada obtenemos:

$$0.91, \quad 0.62, \quad 0.84, \quad 0.39, \quad 0.77.$$

Existe una variabilidad considerable entre las particiones.

Ejemplo

Este patrón puede ser compatible con una elevada varianza del modelo: el resultado depende mucho de qué observaciones aparecen en el conjunto de entrenamiento.

Entre las posibles causas se encuentran:

- modelo excesivamente complejo;
- conjunto de datos pequeño;
- demasiadas variables respecto al número de observaciones;
- presencia de ruido;
- muestras poco representativas;
- dependencia entre observaciones.

Posibles estrategias de investigación:

1. aumentar el tamaño de la muestra;
2. utilizar regularización;
3. reducir la complejidad del modelo;
4. realizar selección de variables;
5. utilizar ensembles;
6. revisar el procedimiento de validación;
7. comprobar si existen grupos o dependencias en los datos.

Atención

No debe identificarse sobreajuste únicamente porque exista una diferencia entre entrenamiento y prueba. También es necesario analizar el tamaño muestral, la distribución de los datos, el protocolo experimental y las características del modelo.

4.4.5. Comparación de los cuatro escenarios

Escenario	Indicador	Problema posible	Investigación
Dataset correcto	Variabilidad estable	No se observa un problema evidente	Continuar evaluación
Valor atípico	Varianza muy elevada	Dato extremo o anomalía	Comprobar origen y contexto
Train/Test diferentes	Varianzas y medias distintas	Cambio de distribución	Analizar muestreo y <i>data drift</i>
Modelo de alta varianza	Métricas muy variables	Posible sobreajuste o inestabilidad	Complejidad, muestra y validación

Cuadro 4.1: Interpretación de la varianza en cuatro escenarios de Machine Learning.

Concepto clave

El análisis de la varianza debe realizarse siempre en contexto. Una varianza grande puede ser una característica natural de los datos, un indicio de valores atípicos, una señal de cambio de distribución o un síntoma de inestabilidad del modelo. La interpretación depende del objeto estadístico que se esté analizando.

4.5. Covarianza

La covarianza estudia cómo varían conjuntamente dos variables:

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

La idea fundamental es multiplicar las desviaciones respecto a sus respectivas medias.

- Si ambas variables tienden a estar por encima de sus medias simultáneamente, los productos tienden a ser positivos.
- Si una suele estar por encima de su media cuando la otra está por debajo, los productos tienden a ser negativos.
- Si no existe un patrón lineal claro, los productos pueden compensarse.

Ejemplo

Consideremos:

$$X = \{1, 2, 3\}$$

y:

$$Y = \{2, 4, 6\}.$$

Las medias son:

$$\bar{x} = 2, \quad \bar{y} = 4.$$

Las desviaciones son:

$$X - \bar{x} = \{-1, 0, 1\}$$

y:

$$Y - \bar{y} = \{-2, 0, 2\}.$$

Los productos son:

$$2, 0, 2.$$

Por tanto:

$$\text{Cov}(X, Y) = \frac{4}{2} = 2.$$

La covarianza positiva refleja que ambas variables aumentan conjuntamente.

4.6. Limitación de la covarianza

La magnitud de la covarianza depende de las unidades de medida.

Si multiplicamos una variable por 100, la covarianza también cambia de escala. Esto dificulta comparar covarianzas obtenidas para variables diferentes.

Por ello se utiliza habitualmente la correlación, que normaliza la covarianza.

4.7. Correlación de Pearson

El coeficiente de correlación de Pearson es:

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}.$$

Equivalentemente:

$$r_{XY} = \frac{\text{Cov}(X, Y)}{s_X s_Y}.$$

El coeficiente cumple:

$$-1 \leq r \leq 1.$$

Una interpretación habitual es:

- $r \approx 1$: relación lineal positiva fuerte;
- $r \approx -1$: relación lineal negativa fuerte;
- $r \approx 0$: ausencia de relación lineal apreciable.

Concepto clave

La correlación de Pearson mide asociación lineal. Un valor cercano a cero no implica necesariamente ausencia de relación: puede existir una relación no lineal.

4.8. Ejemplo detallado de correlación positiva

Consideremos:

$$X = \{1, 2, 3, 4, 5\}$$

y:

$$Y = \{2, 4, 6, 8, 10\}.$$

Existe una relación:

$$Y = 2X.$$

Por tanto, todos los puntos están sobre una recta y:

$$r = 1.$$

Ejemplo

En IA, un ejemplo conceptual sería una variable cuya magnitud aumenta linealmente con otra. Aunque una correlación muy alta facilita detectar relaciones lineales, no demuestra que una variable cause la otra.

4.9. Ejemplo detallado de correlación negativa

Supongamos:

$$X = \{1, 2, 3, 4, 5\}$$

y:

$$Y = \{10, 8, 6, 4, 2\}.$$

Aquí:

$$Y = 12 - 2X.$$

La relación es lineal y descendente, por lo que:

$$r = -1.$$

En un problema de IA, un coeficiente negativo puede indicar que valores altos de una variable tienden a acompañarse de valores bajos de otra.

4.10. Correlación cercana a cero

Considérese una relación no lineal:

$$Y = X^2$$

para valores de X simétricos alrededor de cero.

Puede ocurrir que Pearson sea cercano a cero aunque exista una relación determinista entre ambas variables.

Atención

No debe eliminarse automáticamente una variable porque su correlación de Pearson con la variable objetivo sea próxima a cero. Las relaciones no lineales requieren otras herramientas de análisis.

4.11. Correlación y causalidad

Una correlación estadística no demuestra causalidad.

Puede existir correlación porque:

1. X influye sobre Y ;
2. Y influye sobre X ;
3. existe una tercera variable Z que influye sobre ambas;
4. existe una relación indirecta;

5. se trata de una asociación espuria.

Ejemplo

Si el consumo de electricidad y la temperatura exterior están correlacionados, no significa que uno sea necesariamente la causa directa del otro en todos los contextos. Variables como la estación del año, ocupación de edificios o condiciones meteorológicas pueden influir simultáneamente.

4.12. Correlación y selección de variables

La matriz de correlación puede utilizarse como herramienta exploratoria. Supongamos:

$$r(X_1, X_2) = 0.97.$$

Las dos variables presentan una asociación lineal muy elevada.

En determinados modelos puede existir redundancia. Sin embargo, no debe eliminarse una variable únicamente por presentar alta correlación con otra: la decisión depende del modelo, del objetivo y del significado de las variables.

Ejemplo

En un conjunto de datos de teledetección, dos bandas o índices pueden estar altamente correlacionados porque contienen información relacionada. Un análisis de correlación puede ayudar a detectar redundancias, pero los modelos de árboles, regularización y técnicas de selección de variables pueden responder de forma diferente a esa redundancia.

4.13. Varianza, covarianza y matriz de covarianzas

4.13.1. Ejemplo completo con tres variables

Consideremos tres variables medidas sobre cuatro observaciones:

Cuadro 4.2: Datos de ejemplo para varianza, covarianza y PCA

Observación	X_1	X_2	X_3
1	1	2	5
2	2	4	4
3	3	6	3
4	4	8	2

Las medias son:

$$\bar{X}_1 = 2.5, \quad \bar{X}_2 = 5, \quad \bar{X}_3 = 3.5.$$

Para X_1 , la varianza muestral es:

$$\begin{aligned} s_{X_1}^2 &= \frac{(1 - 2.5)^2 + (2 - 2.5)^2 + (3 - 2.5)^2 + (4 - 2.5)^2}{4 - 1} \\ &= \frac{2.25 + 0.25 + 0.25 + 2.25}{3} = 1.667. \end{aligned}$$

De forma análoga:

$$s_{X_2}^2 = 6.667, \quad s_{X_3}^2 = 1.667.$$

La covarianza entre X_1 y X_2 es:

$$\begin{aligned} \text{Cov}(X_1, X_2) &= \frac{(-1.5)(-3) + (-0.5)(-1) + (0.5)(1) + (1.5)(3)}{3} \\ &= \frac{10}{3} = 3.333. \end{aligned}$$

Por tanto, la covarianza es positiva: ambas variables aumentan conjuntamente.

Entre X_1 y X_3 obtenemos:

$$\text{Cov}(X_1, X_3) = -1.667,$$

lo que indica una relación lineal inversa.

La matriz de covarianzas completa es:

$$\Sigma = \begin{pmatrix} 1.667 & 3.333 & -1.667 \\ 3.333 & 6.667 & -3.333 \\ -1.667 & -3.333 & 1.667 \end{pmatrix}$$

La diagonal contiene las varianzas y los elementos fuera de la diagonal contienen las covarianzas.

Concepto clave

La matriz de covarianzas resume simultáneamente la variabilidad individual de las variables y la forma en que varían conjuntamente. Esta estructura es precisamente la que posteriormente utiliza PCA para encontrar nuevas direcciones de máxima varianza.

4.13.2. Interpretación en Machine Learning

Si estas variables fueran características de un modelo, la matriz anterior mostraría que existe una fuerte redundancia:

$$X_2 = 2X_1, \quad X_3 = 6 - X_1.$$

Por tanto, aunque disponemos de tres columnas, toda la variabilidad está concentrada esencialmente en una única dirección.

Este tipo de situación puede aparecer, de forma menos extrema, cuando trabajamos con bandas espectrales, índices de vegetación o embeddings con componentes muy correlacionadas.

Cuando disponemos de muchas variables, podemos reunir sus covarianzas en una matriz:

$$\Sigma = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}.$$

Los elementos de la diagonal son las varianzas:

$$\Sigma_{ii} = \text{Var}(X_i).$$

Los elementos fuera de la diagonal representan covarianzas.

La matriz de correlaciones puede interpretarse como una versión normalizada de esta estructura.

4.14. Relación con PCA

4.14.1. Ejemplo numérico completo paso a paso

PCA permite transformar variables correlacionadas en componentes ortogonales. Para verlo de forma completa utilizaremos exactamente los datos del ejemplo anterior.

Paso 1. Matriz de datos

$$X = \begin{pmatrix} 1 & 2 & 5 \\ 2 & 4 & 4 \\ 3 & 6 & 3 \\ 4 & 8 & 2 \end{pmatrix}.$$

Paso 2. Centrado

El vector de medias es:

$$\mu = (2.5 \quad 5 \quad 3.5).$$

Restando las medias:

$$X_c = X - \mu = \begin{pmatrix} -1.5 & -3 & 1.5 \\ -0.5 & -1 & 0.5 \\ 0.5 & 1 & -0.5 \\ 1.5 & 3 & -1.5 \end{pmatrix}.$$

Paso 3. Matriz de covarianzas

La matriz se obtiene mediante:

$$\Sigma = \frac{1}{n-1} X_c^T X_c.$$

Por tanto:

$$\Sigma = \begin{pmatrix} 1.667 & 3.333 & -1.667 \\ 3.333 & 6.667 & -3.333 \\ -1.667 & -3.333 & 1.667 \end{pmatrix}.$$

Paso 4. Autovalores y autovectores

PCA resuelve el problema:

$$\Sigma v = \lambda v.$$

Los autovalores obtenidos son, salvo pequeños errores numéricos:

$$\lambda_1 = 10, \quad \lambda_2 = 0, \quad \lambda_3 = 0.$$

La suma de los autovalores coincide con la varianza total:

$$\sum_i \lambda_i = \text{tr}(\Sigma) \approx 10.$$

Un autovector asociado a la primera componente, normalizado, es proporcional a:

$$v_1 = \frac{1}{\sqrt{14}} \begin{pmatrix} 1 \\ 2 \\ -1 \end{pmatrix}.$$

La dirección de PC_1 combina, por tanto, las tres variables originales.

Paso 5. Varianza explicada

La proporción de varianza explicada es:

$$EVR_i = \frac{\lambda_i}{\sum_j \lambda_j}.$$

Así:

$$EVR_1 = 1, \quad EVR_2 = 0, \quad EVR_3 = 0.$$

Por tanto:

$$\boxed{PC_1 \text{ explica el } 100\% \text{ de la varianza}}$$

en este ejemplo idealizado.

Paso 6. Proyección sobre la primera componente

Las coordenadas de las observaciones sobre la primera componente se obtienen mediante:

$$Z = X_c V.$$

Utilizando v_1 :

$$PC_1 = X_c \frac{1}{\sqrt{14}} \begin{pmatrix} 1 \\ 2 \\ -1 \end{pmatrix}.$$

Para la primera observación:

$$PC_{1,1} = \frac{-1.5 - 6 - 1.5}{\sqrt{14}} = -\frac{9}{\sqrt{14}}.$$

Para la segunda:

$$PC_{1,2} = -\frac{3}{\sqrt{14}},$$

y para las restantes:

$$PC_{1,3} = \frac{3}{\sqrt{14}}, \quad PC_{1,4} = \frac{9}{\sqrt{14}}.$$

La información de las tres variables queda así representada mediante una única coordenada por observación.

Paso 7. Reducción de dimensionalidad

Originalmente:

3 variables $\rightarrow$ 3 dimensiones.

Después de conservar únicamente PC_1 :

3 variables $\rightarrow$ 1 dimensión.

En este ejemplo no existe pérdida de varianza porque los datos se encuentran exactamente sobre una recta en el espacio tridimensional.

4.14.2. Ejemplo de implementación con Python

El mismo procedimiento puede reproducirse con `scikit-learn`:

```

1 import numpy as np
2 from sklearn.decomposition import PCA
3
4 X = np.array([
5     [1, 2, 5],
6     [2, 4, 4],
7     [3, 6, 3],
8     [4, 8, 2]
9 ])
10
11 # PCA centra internamente los datos
12 pca = PCA()
13 Z = pca.fit_transform(X)
14
15 print("Componentes:")
16 print(pca.components_)
17
18 print("Autovalores:")
19 print(pca.explained_variance_)
20
21 print("Varianza explicada:")
22 print(pca.explained_variance_ratio_)
23
24 print("Varianza acumulada:")
25 print(np.cumsum(pca.explained_variance_ratio_))

```

Una visualización especialmente útil es el gráfico de varianza explicada:

```

1 import matplotlib.pyplot as plt
2
3 components = np.arange(1, len(
4     pca.explained_variance_ratio_
5 ) + 1)
6
7 plt.bar(
8     components,
9     pca.explained_variance_ratio_
10 )
11 plt.plot(
12     components,
13     np.cumsum(pca.explained_variance_ratio_),
14     marker="o"

```

```

15 )
16
17 plt.xlabel("Componente principal")
18 plt.ylabel("Proporcion de varianza")
19 plt.title("Varianza explicada por PCA")
20 plt.xticks(components)
21 plt.grid(alpha=0.3)
22 plt.show()

```

4.14.3. PCA dentro de un modelo de Machine Learning

Cuando PCA se utiliza como parte de un modelo predictivo, debe evitarse el *data leakage*. PCA no debe ajustarse utilizando simultáneamente entrenamiento y prueba.

El flujo correcto es:

Train/Test → StandardScaler → PCA → Modelo.

Una implementación mediante un Pipeline es:

```

1 from sklearn.pipeline import Pipeline
2 from sklearn.preprocessing import StandardScaler
3 from sklearn.decomposition import PCA
4 from sklearn.ensemble import RandomForestRegressor
5
6 pipeline = Pipeline([
7     ("scaler", StandardScaler()),
8     ("pca", PCA(n_components=0.95)),
9     ("model", RandomForestRegressor(
10         n_estimators=200,
11         random_state=42
12     ))
13 ])

```

El parámetro `n_components=0.95` solicita conservar suficientes componentes para explicar al menos el 95 % de la varianza.

Atención

PCA no garantiza que el modelo predictivo mejore. La reducción de dimensionalidad debe comprobarse experimentalmente mediante validación cruzada y métricas como R^2 , RMSE y MAE. Además, PCA es una transformación no supervisada: maximiza la varianza de los predictores, no directamente su capacidad para predecir la variable objetivo.

4.14.4. Interpretación para teledetección

En un problema de predicción de SOC podemos disponer de numerosas variables:

$\{B2, B3, B4, B8, B11, B12, NDVI, EVI, SAVI, \dots\}$.

Si varias variables presentan covarianzas elevadas, PCA puede producir una representación compacta:

$$X_1, \dots, X_p \longrightarrow PC_1, \dots, PC_k, \quad k < p.$$

La elección de k puede realizarse a partir de la varianza acumulada, pero la decisión final debe validarse respecto al objetivo del modelo.

Concepto clave

La conexión fundamental es:

Varianza → Covarianza → Matriz de covarianzas → Autovectores → Componentes principales

Comprender esta cadena permite interpretar PCA no como una técnica aislada, sino como una consecuencia natural del análisis multivariante de la variabilidad de los datos.

El análisis de componentes principales (PCA) utiliza la estructura de covarianzas o correlaciones para encontrar nuevas direcciones que representan la variabilidad de los datos.

Conceptualmente:

$X \longrightarrow$ matriz de covarianzas $\longrightarrow$ autovectores y autovalores $\longrightarrow$ componentes principales.

Los autovalores están relacionados con la cantidad de varianza explicada por cada componente.

Ejemplo

Si las dos primeras componentes explican el 80 % y el 12 % de la varianza, conjuntamente representan el 92 % de la variabilidad de los datos según la transformación y el conjunto analizado.

4.15. Correlación en datos de IA: precauciones

La correlación debe interpretarse teniendo en cuenta:

- tamaño de muestra;
- valores atípicos;
- relaciones no lineales;
- variables confusoras;
- dependencia temporal;
- dependencia espacial;
- distribución de las variables;
- posible fuga de información.

En datos espaciales y temporales, las observaciones próximas pueden no ser independientes. Por tanto, una correlación calculada ignorando la estructura de dependencia puede sobreestimar la cantidad de información independiente disponible.

4.16. Ejemplo con Python

La varianza y la correlación pueden calcularse con **pandas**:

```

1 import pandas as pd
2
3 df = pd.DataFrame({
4     "x": [1, 2, 3, 4, 5],
5     "y": [2, 4, 6, 8, 10],
6     "z": [10, 8, 7, 5, 4]
7 })
8
9 print("Varianzas:")
10 print(df.var())
11
12 print("\nCovarianzas:")
13 print(df.cov())
14
15 print("\nCorrelaciones:")
16 print(df.corr())

```

También es recomendable visualizar la relación:

```

1 import matplotlib.pyplot as plt
2
3 plt.scatter(df["x"], df["y"])
4 plt.xlabel("X")
5 plt.ylabel("Y")
6 plt.title("Relacion entre X e Y")
7 plt.show()

```

4.17. Ejercicios propuestos

Ejercicio 1. Cálculo de varianza

Para:

$$X = \{2, 4, 4, 6, 8\},$$

calcula:

1. media;
2. varianza poblacional;
3. varianza muestral;
4. desviación típica.

Explica la diferencia entre las dos varianzas.

Ejercicio 2. Comparación de dispersión

Considera:

$$A = \{9, 10, 10, 11, 10\}$$

y:

$$B = \{4, 7, 10, 13, 16\}.$$

Calcula media y desviación típica. Explica qué conjunto presenta mayor variabilidad y por qué.

Ejercicio 3. Covarianza paso a paso

Sean:

$$X = \{1, 2, 3, 4\}$$

y:

$$Y = \{2, 3, 5, 7\}.$$

Calcula las medias, las desviaciones respecto a la media, los productos de desviaciones y finalmente la covarianza muestral.

Ejercicio 4. Correlación positiva

Calcula el coeficiente de Pearson para:

$$X = \{1, 2, 3, 4, 5\}$$

y:

$$Y = \{3, 5, 7, 9, 11\}.$$

Interpreta el resultado.

Ejercicio 5. Correlación negativa

Calcula e interpreta la correlación entre:

$$X = \{1, 2, 3, 4, 5\}$$

y:

$$Y = \{20, 16, 12, 8, 4\}.$$

Explica qué significa el signo del coeficiente.

Ejercicio 6. Correlación y relación no lineal

Genera en Python:

$$X \sim U(-3, 3)$$

y:

$$Y = X^2.$$

Calcula la correlación de Pearson y representa el diagrama de dispersión. Explica por qué una relación evidente puede producir una correlación lineal baja.

Ejercicio 7. Matriz de correlaciones

Crea un conjunto de datos con cinco variables y calcula su matriz de correlaciones. Identifica:

- el par con mayor correlación positiva;
- el par con mayor correlación negativa;
- las variables cuya correlación sea próxima a cero.

Representa la matriz mediante un gráfico.

Ejercicio 8. Correlación y selección de variables

Supón que un dataset contiene:

$$r(X_1, X_2) = 0.97$$

y:

$$r(X_1, Y) = 0.72, \quad r(X_2, Y) = 0.70.$$

Discute si sería razonable eliminar X_1 o X_2 . Considera tanto la redundancia como la posibilidad de que ambas aporten información complementaria.

Ejercicio 9. Varianza de métricas

Un modelo obtiene los siguientes valores de RMSE en cinco particiones:

$$4.1, 4.3, 4.2, 4.0, 8.5.$$

Calcula la media, la varianza y la desviación típica de los RMSE. Analiza el efecto de la quinta partición y explica qué información adicional sería útil investigar.

Ejercicio 10. Mini-proyecto de correlación y varianza

Utiliza un dataset real o sintético con al menos 500 observaciones y realiza:

1. estadística descriptiva;
2. matriz de varianzas y covarianzas;
3. matriz de correlaciones;
4. al menos tres diagramas de dispersión;
5. identificación de relaciones lineales;
6. búsqueda de relaciones no lineales;
7. análisis de posibles valores atípicos;
8. interpretación de las variables más correlacionadas;
9. discusión sobre correlación frente a causalidad;
10. conclusiones sobre qué variables podrían ser útiles para un modelo de Machine Learning.

Capítulo 5

Evaluación de modelos de Machine Learning

Una predicción no es útil únicamente porque produzca un número: es necesario medir su error y analizar cuándo funciona y cuándo falla. Este capítulo introduce residuos y métricas de regresión que permiten evaluar modelos de Machine Learning de forma cuantitativa.




Figura 5.1: Introducción visual: Evaluación de modelos de Machine Learning.

5.1. Residuos

El residuo de una observación es

$$e_i = y_i - \hat{y}_i.$$

El análisis de residuos permite detectar sesgos, heterocedasticidad, valores extremos y patrones no modelizados.

5.2. MAE

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|.$$

5.3. MSE y RMSE

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}.$$

5.4. Coeficiente de determinación

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

Concepto clave

Las métricas deben interpretarse conjuntamente. Un único valor de R^2 , MAE o RMSE no describe por sí solo todo el comportamiento de un modelo.

Capítulo 6

Sesgo, varianza y sobreajuste

La capacidad de generalizar a datos nuevos es uno de los problemas centrales del aprendizaje automático. Este capítulo estudia con detalle el compromiso entre sesgo y varianza, el subajuste y el sobreajuste, la influencia de la complejidad del modelo, las curvas de aprendizaje y las estrategias para controlar la generalización.




Figura 6.1: Relación conceptual entre complejidad, error de entrenamiento y error de generalización.

6.1. Objetivos del capítulo

Al finalizar este capítulo el estudiante será capaz de distinguir sesgo y varianza, diagnosticar subajuste y sobreajuste, interpretar diferencias entre entrenamiento y prueba, analizar curvas de aprendizaje y utilizar regularización y validación cruzada para estudiar la generalización.

6.2. Generalización

Un modelo de Machine Learning debe aprender una relación que pueda aplicarse a observaciones nuevas. Por ello:

error de entrenamiento $\neq$ error de generalización.

Un error de entrenamiento muy pequeño no garantiza que el modelo funcione bien fuera de la muestra utilizada para ajustarlo.

6.3. Sesgo

El **sesgo** (*bias*) representa una componente sistemática del error asociada a las hipótesis o restricciones del modelo.

Supongamos que la relación real es aproximadamente:

$$y = x^2 + \epsilon.$$

Si utilizamos únicamente:

$$\hat{y} = \beta_0 + \beta_1 x,$$

el modelo lineal puede no disponer de suficiente flexibilidad para representar la curvatura.

Concepto clave

Un sesgo elevado suele estar asociado a modelos demasiado simples. El patrón habitual es un rendimiento insuficiente tanto en entrenamiento como en prueba.

6.4. Varianza del modelo

La varianza del modelo describe cuánto cambian sus predicciones cuando cambia la muestra de entrenamiento:

$$\text{Var}[\hat{f}(x)].$$

Un modelo muy flexible puede aprender detalles particulares de una muestra. Al cambiar la muestra, el modelo obtenido puede cambiar considerablemente.

6.5. Descomposición sesgo-varianza

En determinados problemas de regresión, bajo los supuestos habituales:

$$\mathbb{E}[(Y - \hat{f}(X))^2] = \text{Bias}^2 + \text{Variance} + \text{Noise}.$$

Bias^2 representa el error sistemático, Variance la variabilidad de las predicciones entre muestras y Noise el ruido irreducible.

Esta expresión es una herramienta conceptual y no debe extrapolarse automáticamente a cualquier métrica o problema.

6.6. Subajuste y sobreajuste

6.6.1. Subajuste

En el subajuste (*underfitting*) el modelo es demasiado simple.

Un patrón frecuente es:

$$\text{error}_{\text{train}} \text{ alto, } \quad \text{error}_{\text{test}} \text{ alto.}$$

Puede deberse a un modelo demasiado simple, variables insuficientes, regularización excesiva o una representación inadecuada.

6.6.2. Sobreajuste

En el sobreajuste (*overfitting*) el modelo se adapta demasiado a los datos de entrenamiento:

$$\text{error}_{\text{train}} \text{ bajo, } \quad \text{error}_{\text{test}} \text{ alto.}$$

También puede observarse:

$$R_{\text{train}}^2 \gg R_{\text{test}}^2.$$

Entre las causas posibles están la complejidad excesiva, pocos datos, demasiadas variables, ruido, observaciones no representativas o fuga de información.

6.7. Ejemplo comparativo

Cuadro 6.1: Tres comportamientos posibles

Modelo	Error train	Error test	Diagnóstico posible
A	0.42	0.45	Equilibrio razonable
B	0.12	0.48	Sobreajuste
C	0.81	0.85	Subajuste

La tabla es un ejemplo didáctico. El diagnóstico definitivo requiere examinar los datos, la métrica, la validación y el contexto de aplicación.

6.8. Complejidad del modelo

A medida que aumenta la flexibilidad de un modelo, el error de entrenamiento suele disminuir. El error de generalización puede primero mejorar y después empeorar:

$$\text{complejidad} \uparrow \Rightarrow \begin{cases} \text{error train} \downarrow, \\ \text{error test} \downarrow \text{ inicialmente,} \\ \text{error test} \uparrow \text{ tras sobreajuste.} \end{cases}$$

Por ello no se busca el modelo más complejo, sino una complejidad compatible con la generalización.

6.9. Curvas de aprendizaje

Las curvas de aprendizaje representan el rendimiento en función del número de observaciones utilizadas para entrenar.

Si entrenamiento y validación convergen hacia un error alto, puede existir subajuste. Si entrenamiento mantiene un error muy bajo y validación un error mucho mayor, puede existir sobreajuste.

Las curvas deben interpretarse junto con la distribución de los datos y el procedimiento de validación.

6.10. Regularización

Ridge añade una penalización cuadrática:

$$\mathcal{L}_{Ridge} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2.$$

Lasso utiliza una penalización L_1 :

$$\mathcal{L}_{Lasso} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p |\beta_j|.$$

El parámetro λ controla la intensidad de la regularización. Una regularización excesiva puede aumentar el sesgo; una regularización insuficiente puede dejar demasiado margen para el sobreajuste.

6.11. Validación cruzada y estabilidad

Con validación cruzada K -fold obtenemos:

$$M_1, M_2, \dots, M_K.$$

La media es:

$$\bar{M} = \frac{1}{K} \sum_{k=1}^K M_k$$

y la varianza de las métricas:

$$s_M^2 = \frac{1}{K-1} \sum_{k=1}^K (M_k - \bar{M})^2.$$

Por ejemplo:

$$R^2 = \{0.91, 0.62, 0.84, 0.39, 0.77\}.$$

La media es:

$$\bar{R}^2 = 0.706.$$

La amplitud entre el mejor y el peor fold es:

$$0.91 - 0.39 = 0.52.$$

Una dispersión tan grande merece investigación. Puede deberse al algoritmo, pero también a pocos datos, diferencias espaciales o temporales, dependencia entre observaciones, outliers o cambios de distribución.

6.12. Estrategias de control del sobreajuste

1. aumentar la cantidad y diversidad de datos;
2. simplificar el modelo;
3. utilizar regularización;

4. seleccionar variables;
5. reducir dimensionalidad cuando esté justificado;
6. emplear validación cruzada;
7. limitar la profundidad de árboles;
8. revisar la fuga de información;
9. utilizar ensembles cuando resulte apropiado;
10. diseñar una validación coherente con la estructura temporal o espacial.

6.13. Ejemplo práctico con Python

```
1 import numpy as np
2 from sklearn.model_selection import train_test_split
3 from sklearn.preprocessing import PolynomialFeatures
4 from sklearn.linear_model import LinearRegression
5 from sklearn.pipeline import Pipeline
6 from sklearn.metrics import mean_squared_error
7
8 rng = np.random.default_rng(42)
9
10 X = np.linspace(-3, 3, 100).reshape(-1, 1)
11 y = X[:, 0]**2 + rng.normal(0, 1, len(X))
12
13 X_train, X_test, y_train, y_test = train_test_split(
14     X, y, test_size=0.30, random_state=42
15 )
16
17 for degree in [1, 2, 5, 15]:
18     model = Pipeline([
19         ("poly", PolynomialFeatures(degree=degree)),
20         ("reg", LinearRegression())
21     ])
22
23     model.fit(X_train, y_train)
24
25     train_pred = model.predict(X_train)
26     test_pred = model.predict(X_test)
27
28     train_rmse = mean_squared_error(
29         y_train, train_pred, squared=False
30     )
31     test_rmse = mean_squared_error(
32         y_test, test_pred, squared=False
33     )
34
35     print(degree, train_rmse, test_rmse)
```

El experimento permite observar que la complejidad afecta de forma distinta al error de entrenamiento y al de generalización.

6.14. Varianza de los datos frente a varianza del modelo

Es importante no confundir:

varianza de los datos $\neq$ varianza del modelo

Una variable puede presentar elevada dispersión porque el fenómeno estudiado es heterogéneo. Esto no implica necesariamente un modelo de alta varianza.

Por otra parte, un modelo puede ser inestable aunque cada variable individual tenga una dispersión moderada.

6.15. Checklist de diagnóstico

1. ¿La muestra representa la población objetivo?
2. ¿Hay diferencias entre entrenamiento y prueba?
3. ¿Existen valores atípicos o errores de adquisición?
4. ¿Hay fuga de información?
5. ¿La métrica es adecuada?
6. ¿El rendimiento cambia mucho entre folds?
7. ¿El modelo es excesivamente complejo?
8. ¿La regularización está correctamente ajustada?
9. ¿Se respeta la estructura temporal o espacial?
10. ¿Qué parte del error es irreducible?

6.16. Resumen

El marco conceptual puede resumirse como:

Modelo demasiado simple $\rightarrow$ sesgo elevado $\rightarrow$ subajuste

y:

Modelo excesivamente flexible $\rightarrow$ varianza elevada $\rightarrow$ sobreajuste potencial

La validación cruzada, la regularización, el control de complejidad y el análisis de los datos deben utilizarse conjuntamente para estudiar la generalización.

Capítulo 7

Muestreo y validación cruzada

La evaluación de un modelo depende de cómo se seleccionan y separan los datos. Este capítulo estudia estrategias de muestreo y validación cruzada, así como el riesgo de obtener estimaciones optimistas por fuga de información.

CAPÍTULO 7

Muestreo y validación cruzada

Muestra → particiones → folds → estimación del rendimiento



Figura 7.1: Introducción visual: Muestreo y validación cruzada.

7.1. División de los datos

Un conjunto de datos puede dividirse en entrenamiento, validación y prueba. La proporción depende del tamaño y de la naturaleza del problema.

7.2. k -fold cross-validation

En k -fold cross-validation se divide el conjunto en k particiones. Cada partición se utiliza una vez como validación y las restantes para entrenamiento.

Si M_j es la métrica obtenida en el pliegue j :

$$\overline{M} = \frac{1}{k} \sum_{j=1}^k M_j.$$

También resulta útil informar de la variabilidad entre pliegues.

Atención

Todas las transformaciones que aprenden parámetros a partir de los datos deben ajustarse dentro de cada partición de entrenamiento para evitar *data leakage*.

Capítulo 8

Inferencia estadística e incertidumbre

Los modelos estadísticos y de IA trabajan con incertidumbre. Este capítulo introduce intervalos de confianza, pruebas de hipótesis y formas de expresar la incertidumbre asociada a una predicción.




Figura 8.1: Introducción visual: Inferencia estadística e incertidumbre.

8.1. Intervalos de confianza

Bajo determinadas hipótesis, un intervalo para una media puede expresarse como

$$\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

Cuando la desviación poblacional es desconocida pueden utilizarse procedimientos basados en la distribución t de Student.

8.2. Pruebas de hipótesis

Se formulan una hipótesis nula H_0 y una hipótesis alternativa H_1 . El valor p mide, bajo el modelo de H_0 , la compatibilidad de los datos con resultados tan extremos o más extremos que los observados.

Atención

El valor p no es la probabilidad de que H_0 sea verdadera.

8.3. Incertidumbre en predicciones

Una predicción puede representarse como

$$\hat{y} \pm \sigma.$$

Bajo hipótesis adicionales, una aproximación normal puede producir:

$$I_{95\%} = [\hat{y} - 1.96\sigma, \hat{y} + 1.96\sigma].$$

Entre los enfoques disponibles se encuentran bootstrap, ensembles, modelos probabilísticos, análisis de residuos y métodos conformales.

Capítulo 9

Preprocesamiento estadístico

Los datos reales contienen escalas diferentes, valores ausentes, observaciones extremas y otras imperfecciones. Este capítulo presenta transformaciones estadísticas habituales y explica cómo aplicarlas sin contaminar la evaluación del modelo.

CAPÍTULO 9

Preprocesamiento estadístico

Datos brutos → limpieza → transformación → variables




Figura 9.1: Introducción visual: Preprocesamiento estadístico.

9.1. Estandarización

$$z_i = \frac{x_i - \mu}{\sigma}.$$

9.2. Escalado Min-Max

$$x'_i = \frac{x_i - x_{\text{mín}}}{x_{\text{máx}} - x_{\text{mín}}}.$$

Concepto clave

Los parámetros de las transformaciones deben estimarse utilizando únicamente los datos de entrenamiento y aplicarse posteriormente a validación y prueba.

9.3. Valores atípicos

Los valores atípicos pueden identificarse mediante métodos basados en IQR, puntuaciones estandarizadas, distancia o métodos específicos del dominio.

No todo valor extremo es necesariamente un error: puede representar una observación real importante.

Capítulo 10

Ejemplo práctico con Python

La teoría estadística adquiere especial utilidad cuando se traduce en un flujo reproducible de análisis. Este capítulo muestra un ejemplo compacto con Python y scikit-learn que puede servir como plantilla para prácticas posteriores.



Figura 10.1: Introducción visual: Ejemplo práctico con Python.

El siguiente ejemplo construye un modelo de regresión y calcula varias métricas:

```
1 import numpy as np
2 import pandas as pd
3
4 from sklearn.model_selection import train_test_split
5 from sklearn.ensemble import RandomForestRegressor
6 from sklearn.metrics import (
7     mean_absolute_error,
8     mean_squared_error,
9     r2_score
10 )
11
12 X = pd.DataFrame({
13     "feature_1": [1, 2, 3, 4, 5, 6, 7, 8],
14     "feature_2": [2, 3, 4, 5, 6, 7, 8, 9]
```

```
15 })
16
17 y = np.array([3, 5, 7, 9, 11, 13, 15, 17])
18
19 X_train, X_test, y_train, y_test = train_test_split(
20     X, y, test_size=0.25, random_state=42
21 )
22
23 model = RandomForestRegressor(
24     n_estimators=100,
25     random_state=42
26 )
27
28 model.fit(X_train, y_train)
29 y_pred = model.predict(X_test)
30
31 mae = mean_absolute_error(y_test, y_pred)
32 rmse = np.sqrt(mean_squared_error(y_test, y_pred))
33 r2 = r2_score(y_test, y_pred)
34
35 print("MAE:", mae)
36 print("RMSE:", rmse)
37 print("R2:", r2)
```

Capítulo 11

Caso aplicado: predicción de una variable ambiental

Los problemas ambientales constituyen un contexto especialmente útil para integrar estadística, teledetección y Machine Learning. El capítulo muestra cómo formular matemáticamente un problema de predicción a partir de variables heterogéneas y qué aspectos de muestreo y dependencia espacial deben considerarse.

CAPÍTULO 11

Predicción de una variable ambiental




Figura 11.1: Introducción visual: Caso aplicado: predicción de una variable ambiental.

Supongamos un problema en el que queremos estimar una variable ambiental a partir de datos de teledetección, información topográfica y representaciones obtenidas mediante modelos fundacionales.

La matriz de características puede expresarse como

$$X = \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,1} & x_{n,2} & \cdots & x_{n,p} \end{bmatrix}.$$

El vector objetivo es

$$y = \begin{bmatrix} y_1 & y_2 & \cdots & y_n \end{bmatrix}^T.$$

El objetivo consiste en aprender

$$f : X \rightarrow y$$

y obtener

$$\hat{y} = f(X).$$

En aplicaciones ambientales resulta especialmente importante tener en cuenta la distribución espacial de las muestras, la posible dependencia espacial, la representatividad de las observaciones y la independencia entre entrenamiento y prueba.

Capítulo 12

Ejercicios

Los ejercicios permiten comprobar la comprensión de los conceptos y trasladar la teoría a problemas de cálculo y programación. Se incluyen actividades progresivas, desde estadística descriptiva hasta comparación de modelos.




Figura 12.1: Introducción visual: Ejercicios.

12.1. Ejercicio 1: estadística descriptiva

Dados

12, 15, 18, 20, 20, 22, 25, 30

calcular media, mediana, moda, rango, desviación típica y cuartiles.

12.2. Ejercicio 2: métricas

Para

$y = [10, 20, 30, 40, 50]$

y

$$\hat{y} = [12, 18, 29, 44, 48]$$

calcular MAE, RMSE y residuos.

12.3. Ejercicio 3: sobreajuste

Un modelo obtiene $R^2 = 0.82$ en entrenamiento y $R^2 = 0.54$ en prueba. Analizar qué hipótesis deben investigarse para explicar la diferencia.

12.4. Ejercicio 4: distribuciones

Generar en Python 1000 observaciones de distribuciones normal, uniforme y exponencial. Representarlas mediante histogramas y comparar sus estadísticos descriptivos.

12.5. Ejercicio 5: comparación de modelos

Construir modelos de regresión lineal, Random Forest y Gradient Boosting. Compararlos utilizando MAE, RMSE y R^2 , evitando utilizar el conjunto de prueba durante la selección del modelo.

Resumen de conceptos

CAPÍTULO 13

Resumen de conceptos




Figura 12.2: Introducción visual: Resumen de conceptos.

Concepto	Aplicación
Media	Tendencia central
Mediana	Posición central robusta
Varianza	Dispersión
Desviación típica	Variabilidad
Percentiles	Posición relativa
Correlación	Relación lineal
Probabilidad	Incertidumbre
Regresión	Predicción
Residuos	Análisis del error
MAE	Error absoluto medio
RMSE	Error cuadrático medio
R^2	Variabilidad explicada
Cross-validation	Evaluación del rendimiento
Intervalos	Cuantificación de incertidumbre

Cuadro 12.1: Resumen de conceptos fundamentales.

Índice de fórmulas

Índice de fórmulas

Coeficiente de determinación R^2 , 38

Correlación de Pearson, 25

Covarianza, 24

Descomposición sesgo-varianza, 40

Desviación típica, 7, 20

Escalado Min-Max, 49

Estandarización, 49

Intervalo aproximado de predicción al 95
por ciento, 48

Intervalo de confianza de la media, 47

Lasso, 42

MAE, 38

Media aritmética, 5

Media de validación cruzada, 46

MSE, 38

Predicción con incertidumbre, 48

Rango intercuartílico, 8

Residuo, 37

Ridge, 42

RMSE, 38

Varianza, 7

Varianza muestral, 19

Varianza poblacional, 18

Bibliografía