

IFCD107

Especialista en Inteligencia Artificial

Tema 1. Fundamentos de Inteligencia Artificial

Material docente

22 de septiembre de 2026

Referencia oficial

Este documento desarrolla el **Módulo de Formación 1: Fundamentos de Inteligencia Artificial** de la especialidad **IFCD107 – Especialista en Inteligencia Artificial**. El programa oficial establece una duración de **42 horas**. El contenido de este documento desarrolla pedagógicamente los resultados de aprendizaje oficiales; la distribución interna de horas por unidades es una **propuesta docente**, no una subdivisión oficial del SEPE.

Índice general

Presentación	vi
1. Marco del módulo	1
1.1. Identificación	1
1.2. Objetivo oficial	1
1.3. Resultados de aprendizaje	1
1.4. Competencias de gestión, personales y sociales	2
2. Índice general del Tema 1	3
3. Inmersión a la IA explicando sus principales modalidades	4
3.1. Concepto de Inteligencia Artificial	4
3.2. Evolución de la Inteligencia Artificial	4
3.3. IA débil e IA general	4
3.4. Principales modalidades	5
3.4.1. IA simbólica	5
3.4.2. Machine Learning	5
3.4.3. Deep Learning	5
3.4.4. IA generativa	5
3.5. Áreas de aplicación	5
3.6. IA, ML y Deep Learning	5
3.7. Caso práctico	6
4. Breve noción sobre los principales algoritmos de IA	7
4.1. Clasificación general	7
4.2. Regresión lineal	7
4.3. Árboles de decisión	7
4.4. Random Forest	8
4.5. Gradient Boosting	8
4.6. K-Nearest Neighbors	8
4.7. Support Vector Machine	8
4.8. K-Means	8
4.9. Redes neuronales	8
4.10. Selección del algoritmo	8
5. Análisis de los diferentes tipos de aprendizaje	9
5.1. Aprendizaje supervisado	9
5.1.1. Clasificación	9
5.1.2. Regresión	9
5.2. Aprendizaje no supervisado	9
5.3. Aprendizaje semisupervisado	9
5.4. Aprendizaje por refuerzo	10

5.5. Entrenamiento, validación y prueba	10
5.6. Sobreajuste y subajuste	10
5.7. Validación cruzada	10
5.8. Métricas	10
6. Fundamentos matemáticos para el entendimiento del funcionamiento de distintos algoritmos basados en IA y conceptos básicos de programación	11
6.1. Variables y funciones	11
6.2. Vectores	11
6.3. Matrices	11
6.4. Producto escalar	11
6.5. Normas y distancias	12
6.6. Derivadas y gradiente	12
6.7. Probabilidad	12
6.8. Conceptos básicos de programación	12
7. Implementación de conceptos matemáticos de IA utilizando Python como lenguaje de programación	13
7.1. NumPy	13
7.2. Operaciones matriciales	13
7.3. Distancia euclídea	13
7.4. Normalización	14
7.5. Función de pérdida	14
7.6. Gradiente de una función sencilla	14
8. Fundamentos estadísticos básicos para el entendimiento del funcionamiento de distintos algoritmos, preprocesamiento de datos y análisis de resultados	15
8.1. Estadística descriptiva	15
8.2. Mediana y cuantiles	15
8.3. Covarianza	15
8.4. Correlación de Pearson	16
8.5. Valores ausentes	16
8.6. Valores atípicos	16
8.7. Sesgo y fuga de información	16
8.8. Distribuciones y normalidad	16
8.9. Análisis de errores	16
9. Implementación de conceptos estadísticos utilizando Python como lenguaje de programación	17
9.1. pandas	17
9.2. Media, mediana y desviación	17
9.3. Correlaciones	17
9.4. Cuantiles	17
9.5. Visualización	18
9.6. Análisis de residuos	18
9.7. Métricas con scikit-learn	18
10. Puesta en marcha del entorno de trabajo	19
10.1. Arquitectura del entorno	19
10.2. Entornos virtuales	19
10.3. Instalación de paquetes	19
10.4. Jupyter	19

10.5. Comprobación del entorno	19
10.6. Reproducibilidad	20
11. Detalle de los diferentes softwares y programas utilizados para la implementación de algoritmos basados en IA	21
11.1. Python	21
11.2. JupyterLab	21
11.3. Visual Studio Code	21
11.4. NumPy	21
11.5. pandas	21
11.6. Matplotlib	21
11.7. scikit-learn	21
11.8. Otras bibliotecas	22
11.9. Control de versiones	22
12. Inmersión en el lenguaje Python	23
12.1. Variables y tipos	23
12.2. Estructuras de datos	23
12.3. Condicionales	23
12.4. Bucles	23
12.5. Funciones	23
12.6. Comprensiones	24
12.7. Excepciones	24
12.8. Programación orientada a objetos	24
12.9. Buenas prácticas	24
13. Resumen	25
14. Actividades tipo test	26
14.1. Test de conceptos fundamentales	26
14.2. Preguntas de desarrollo	27
14.3. Práctica final	27
14.4. Soluciones orientativas	28
14.5. Checklist de finalización	28
A. Glosario básico	29
B. Referencia oficial	30

Índice de cuadros

1.1. Identificación del módulo.	1
4.1. Familias de algoritmos introducidas en el módulo.	7

Presentación

Este tema proporciona la base conceptual, matemática, estadística y de programación necesaria para abordar posteriormente Machine Learning, redes neuronales, AutoML y proyectos de Inteligencia Artificial.

El módulo se plantea con una orientación eminentemente práctica. Cada bloque combina conceptos, ejemplos, ejercicios y actividades con Python. Se pretende que el alumnado no solo conozca terminología de Inteligencia Artificial, sino que sea capaz de interpretar un problema, seleccionar una técnica básica y construir pequeños experimentos reproducibles.

Capítulo 1

Marco del módulo

1.1. Identificación

Especialidad	IFCD107 – Especialista en Inteligencia Artificial
Módulo	Módulo 1 – Fundamentos de Inteligencia Artificial
Duración oficial	42 horas
Nivel de cualificación	3
Familia profesional	Informática y Comunicaciones
Área profesional	Desarrollo
Modalidad oficial	Presencial

Cuadro 1.1: Identificación del módulo.

1.2. Objetivo oficial

El objetivo del módulo es adquirir los conceptos básicos, herramientas y lenguajes relacionados con la Inteligencia Artificial y sus diferentes modalidades.

1.3. Resultados de aprendizaje

De acuerdo con el programa oficial, el módulo aborda:

1. Inmersión en la Inteligencia Artificial y sus principales modalidades.
2. Noción de los principales algoritmos de Inteligencia Artificial.
3. Análisis de los diferentes tipos de aprendizaje.
4. Fundamentos matemáticos necesarios para comprender algoritmos de IA.
5. Conceptos básicos de programación e implementación matemática con Python.
6. Fundamentos estadísticos para comprender algoritmos, preprocesamiento y análisis.
7. Implementación de conceptos estadísticos mediante Python.
8. Puesta en marcha del entorno de trabajo.
9. Conocimiento del software utilizado para implementar algoritmos de IA.
10. Inmersión en el lenguaje Python.

1.4. Competencias de gestión, personales y sociales

Se trabajarán especialmente la autonomía en el aprendizaje, la resolución de problemas en contextos nuevos, la aplicación práctica de Python y el desarrollo de funciones matemáticas y estadísticas mediante programación.

Capítulo 2

Índice general del Tema 1

El desarrollo del módulo se organiza en doce unidades didácticas, siguiendo la estructura mostrada en el material de referencia. Las horas indicadas constituyen una propuesta de secuenciación docente dentro de las 42 horas oficiales del módulo.

1. Inmersión a la IA explicando sus principales modalidades.
2. Breve noción sobre los principales algoritmos de IA.
3. Análisis de los diferentes tipos de aprendizaje.
4. Fundamentos matemáticos para el entendimiento del funcionamiento de distintos algoritmos basados en IA y conceptos básicos de programación.
5. Implementación de conceptos matemáticos de IA utilizando Python como lenguaje de programación.
6. Fundamentos estadísticos básicos para el entendimiento del funcionamiento de distintos algoritmos, preprocesamiento de datos y análisis de resultados.
7. Implementación de conceptos estadísticos utilizando Python como lenguaje de programación.
8. Puesta en marcha del entorno de trabajo.
9. Detalle de los diferentes softwares y programas utilizados para la implementación de algoritmos basados en IA.
10. Inmersión en el lenguaje Python.
11. Resumen.
12. Actividades tipo test.

Capítulo 3

Inmersión a la IA explicando sus principales modalidades

3.1. Concepto de Inteligencia Artificial

La Inteligencia Artificial (IA) es un campo de la informática dedicado al diseño de sistemas capaces de realizar tareas que requieren capacidades como percepción, clasificación, predicción, razonamiento, planificación, comprensión del lenguaje o generación de contenido.

Una definición operativa para este curso es:

Idea clave

La IA no es un único algoritmo. Es un conjunto de técnicas y paradigmas que permiten resolver problemas mediante reglas, búsqueda, optimización, representación del conocimiento y aprendizaje a partir de datos.

3.2. Evolución de la Inteligencia Artificial

La evolución de la IA puede estudiarse mediante varias etapas:

1. IA simbólica y sistemas basados en reglas.
2. Sistemas expertos y representación del conocimiento.
3. Métodos estadísticos y Machine Learning.
4. Deep Learning y redes neuronales profundas.
5. Modelos fundacionales y sistemas generativos multimodales.

Estas etapas no sustituyen completamente a las anteriores. En aplicaciones reales coexisten reglas, algoritmos estadísticos, modelos de Machine Learning y redes neuronales.

3.3. IA débil e IA general

La denominada IA estrecha o especializada está diseñada para una tarea o conjunto limitado de tareas. Un clasificador de imágenes, un detector de fraude o un sistema de recomendación son ejemplos de este enfoque.

La Inteligencia Artificial General (AGI) es un concepto de investigación que se refiere a sistemas con capacidades generales comparables a las de las personas en una amplia variedad de tareas. No debe confundirse con las aplicaciones concretas de IA utilizadas actualmente.

3.4. Principales modalidades

3.4.1. IA simbólica

Utiliza reglas, lógica, ontologías y representación explícita del conocimiento.

3.4.2. Machine Learning

Los algoritmos aprenden relaciones a partir de ejemplos:

$$f : X \rightarrow Y.$$

3.4.3. Deep Learning

Utiliza redes neuronales con múltiples capas para aprender representaciones a partir de grandes cantidades de datos.

3.4.4. IA generativa

Los modelos generativos producen nuevas instancias de una modalidad de datos, por ejemplo texto, imágenes, audio o código.

3.5. Áreas de aplicación

- visión por computador;
- procesamiento del lenguaje natural;
- sistemas de recomendación;
- detección de anomalías;
- predicción y series temporales;
- robótica;
- mantenimiento predictivo;
- agricultura de precisión;
- ciberseguridad;
- automatización de procesos.

3.6. IA, ML y Deep Learning

La relación pedagógica más habitual es:

$$IA \supset Machine\ Learning \supset Deep\ Learning.$$

Machine Learning constituye una parte de la IA y Deep Learning una familia de técnicas dentro de Machine Learning. No todos los sistemas de IA utilizan aprendizaje automático.

3.7. Caso práctico

Supóngase un problema de predicción del carbono orgánico del suelo. Las variables espectrales, climáticas, topográficas y las representaciones derivadas de imágenes pueden utilizarse como entradas $\mathbf{x}$ y el contenido de carbono como variable objetivo y :

$$\hat{y} = f(\mathbf{x}).$$

El objetivo del proyecto será construir y evaluar f con datos que no hayan sido utilizados para ajustar el modelo.

Capítulo 4

Breve noción sobre los principales algoritmos de IA

4.1. Clasificación general

Los algoritmos pueden agruparse en función del problema:

Problema	Algoritmos	Aplicación
Regresión	Regresión lineal, árboles, Random Forest, Gradient Boosting	Predicción numérica
Clasificación	Regresión logística, KNN, SVM, árboles, ensembles	Clases o categorías
Clustering	K-Means, clustering jerárquico	Agrupación de observaciones
Reducción de dimensión	PCA, métodos de representación	Compresión y visualización
Deep Learning	MLP, CNN, RNN, Transformers	Datos complejos y multimodales

Cuadro 4.1: Familias de algoritmos introducidas en el módulo.

4.2. Regresión lineal

El modelo lineal se expresa como:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p.$$

Los parámetros se estiman minimizando normalmente el error cuadrático:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

4.3. Árboles de decisión

Un árbol divide el espacio de características mediante reglas sucesivas. En regresión, cada hoja puede producir un valor numérico; en clasificación, una clase o una distribución de clases.

4.4. Random Forest

Random Forest combina múltiples árboles entrenados sobre muestras y subconjuntos aleatorios de variables. Para regresión, una predicción habitual es:

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B \hat{y}_b.$$

4.5. Gradient Boosting

Los métodos de boosting construyen modelos secuencialmente, intentando corregir los errores de los modelos anteriores.

4.6. K-Nearest Neighbors

KNN utiliza la proximidad entre observaciones. Para una consulta $\mathbf{x}$ se identifican sus k vecinos más próximos y se utiliza su información para producir la predicción.

4.7. Support Vector Machine

SVM busca una separación adecuada entre clases o una función de regresión que mantenga los errores dentro de un margen determinado.

4.8. K-Means

K-Means divide las observaciones en k grupos minimizando:

$$J = \sum_{j=1}^k \sum_{\mathbf{x}_i \in C_j} \left\| \mathbf{x}_i - \boldsymbol{\mu}_j \right\|^2.$$

4.9. Redes neuronales

Una neurona artificial puede representarse como:

$$z = \sum_{j=1}^p w_j x_j + b, \quad a = \phi(z),$$

donde ϕ es una función de activación.

4.10. Selección del algoritmo

La selección debe depender del problema, los datos, el tamaño de la muestra, la interpretabilidad requerida, los recursos computacionales y la métrica de evaluación. No existe un algoritmo universalmente óptimo.

Capítulo 5

Análisis de los diferentes tipos de aprendizaje

5.1. Aprendizaje supervisado

Disponemos de pares:

$$D = \{(\mathbf{x}_i, y_i)\}_{i=1}^n.$$

El modelo aprende una función que relaciona entradas con salidas.

5.1.1. Clasificación

La variable objetivo es categórica:

$$y \in \{c_1, \dots, c_k\}.$$

Ejemplos: spam/no spam, tipo de cultivo o presencia/ausencia de una enfermedad.

5.1.2. Regresión

La variable objetivo es numérica:

$$y \in \mathbb{R}.$$

Ejemplos: precio, temperatura o carbono orgánico del suelo.

5.2. Aprendizaje no supervisado

No se dispone de una etiqueta objetivo. El algoritmo busca estructuras internas en los datos, por ejemplo grupos o representaciones de menor dimensión.

5.3. Aprendizaje semisupervisado

Combina un conjunto pequeño de datos etiquetados con una cantidad mayor de observaciones sin etiqueta.

5.4. Aprendizaje por refuerzo

Un agente interactúa con un entorno:

$$s_t \rightarrow a_t \rightarrow r_t \rightarrow s_{t+1}.$$

El objetivo es encontrar una política $\pi(a|s)$ que maximice la recompensa acumulada.

5.5. Entrenamiento, validación y prueba

Una división básica es:

$$D = D_{\text{train}} \cup D_{\text{validation}} \cup D_{\text{test}}.$$

La separación evita evaluar el modelo sobre los mismos datos utilizados para ajustarlo.

5.6. Sobreajuste y subajuste

El *overfitting* aparece cuando el modelo aprende demasiado específicamente los datos de entrenamiento. El *underfitting* ocurre cuando el modelo no tiene capacidad suficiente para representar la relación existente.

5.7. Validación cruzada

En K -fold cross-validation se dividen los datos en K particiones y se realizan varios entrenamientos:

$$\text{Score}_{CV} = \frac{1}{K} \sum_{k=1}^K \text{Score}_k.$$

5.8. Métricas

Para regresión se estudiarán:

$$\text{MAE} = \frac{1}{n} \sum_i |y_i - \hat{y}_i|,$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2},$$

y el coeficiente de determinación:

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

Capítulo 6

Fundamentos matemáticos para el entendimiento del funcionamiento de distintos algoritmos basados en IA y conceptos básicos de programación

6.1. Variables y funciones

Una función asigna valores de un dominio a un codominio:

$$f : X \rightarrow Y.$$

En Machine Learning, una observación puede representarse mediante:

$$\mathbf{x} = (x_1, x_2, \dots, x_p).$$

6.2. Vectores

Los vectores permiten representar observaciones, parámetros y gradientes. Por ejemplo:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}.$$

6.3. Matrices

Un dataset puede representarse como:

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

6.4. Producto escalar

$$\mathbf{w}^T \mathbf{x} = \sum_{j=1}^p w_j x_j.$$

Este concepto aparece directamente en modelos lineales y en cada neurona de una red.

6.5. Normas y distancias

La norma euclídea es:

$$\|\mathbf{x}\|_2 = \sqrt{\sum_j x_j^2}.$$

La distancia entre dos observaciones es:

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2.$$

6.6. Derivadas y gradiente

Para una función $L(\theta)$:

$$\nabla L(\theta) = \left[\frac{\partial L}{\partial \theta_1}, \dots, \frac{\partial L}{\partial \theta_p} \right]^T.$$

El descenso por gradiente utiliza:

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t).$$

6.7. Probabilidad

La probabilidad permite modelar incertidumbre. Para sucesos A y B :

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

El teorema de Bayes establece:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}.$$

6.8. Conceptos básicos de programación

Se introducirán variables, tipos de datos, operadores, estructuras condicionales, bucles, funciones, listas, diccionarios y módulos.

```
def media(valores):
    return sum(valores) / len(valores)

datos = [10, 20, 30, 40]
print(media(datos))
```

Capítulo 7

Implementación de conceptos matemáticos de IA utilizando Python como lenguaje de programación

7.1. NumPy

NumPy proporciona estructuras y operaciones eficientes para cálculo numérico.

```
import numpy as np

x = np.array([1, 2, 3])
w = np.array([0.5, 0.2, 0.1])

producto = np.dot(x, w)
print(producto)
```

7.2. Operaciones matriciales

```
X = np.array([
    [1, 2],
    [3, 4],
    [5, 6]
])

w = np.array([0.5, 0.25])
b = 1.0

y = X @ w + b
print(y)
```

7.3. Distancia euclídea

```
def distancia_euclidea(a, b):
    return np.sqrt(np.sum((a - b) ** 2))

a = np.array([1, 2])
b = np.array([4, 6])

print(distancia_euclidea(a, b))
```

7.4. Normalización

```
def estandarizar(x):  
    return (x - np.mean(x)) / np.std(x)  
  
x = np.array([10, 20, 30, 40])  
print(estandarizar(x))
```

7.5. Función de pérdida

La implementación de MSE puede realizarse mediante:

```
def mse(y_true, y_pred):  
    error = y_true - y_pred  
    return np.mean(error ** 2)
```

7.6. Gradiente de una función sencilla

Para:

$$f(x) = x^2,$$

su derivada es:

$$f'(x) = 2x.$$

```
def gradiente(x):  
    return 2 * x  
  
x = 5.0  
learning_rate = 0.1  
  
for _ in range(10):  
    x = x - learning_rate * gradiente(x)  
  
print(x)
```

Capítulo 8

Fundamentos estadísticos básicos para el entendimiento del funcionamiento de distintos algoritmos, preprocesamiento de datos y análisis de resultados

8.1. Estadística descriptiva

La media:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

La varianza:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

La desviación típica:

$$s = \sqrt{s^2}.$$

8.2. Mediana y cuantiles

Los cuantiles permiten dividir una distribución ordenada en proporciones. Los cuantiles son especialmente útiles para estudiar distribuciones asimétricas y analizar el error del modelo en diferentes zonas de la variable objetivo.

8.3. Covarianza

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_i (x_i - \bar{x})(y_i - \bar{y}).$$

8.4. Correlación de Pearson

$$r = \frac{\text{Cov}(X, Y)}{s_X s_Y}.$$

Valores próximos a 1 indican asociación lineal positiva; valores próximos a -1 , asociación lineal negativa; valores próximos a 0 indican ausencia de asociación lineal, aunque no necesariamente independencia.

8.5. Valores ausentes

Los datos ausentes deben identificarse antes del entrenamiento:

```
import pandas as pd

df = pd.read_csv("datos.csv")
print(df.isna().sum())
```

Las estrategias dependen del problema: eliminación, imputación estadística, interpolación o modelos específicos.

8.6. Valores atípicos

Un valor atípico es una observación que se separa notablemente del patrón de los datos. No debe eliminarse automáticamente: primero debe comprobarse si representa un error, un caso real o una característica importante de la población.

8.7. Sesgo y fuga de información

El preprocesamiento debe ajustarse utilizando únicamente el conjunto de entrenamiento cuando exista riesgo de fuga de información.

Por ejemplo, un escalador debe aprender μ y σ del entrenamiento y después aplicarse al conjunto de prueba:

$$z_{\text{test}} = \frac{x_{\text{test}} - \mu_{\text{train}}}{\sigma_{\text{train}}}.$$

8.8. Distribuciones y normalidad

Se introducirán la distribución normal, asimetría, curtosis y transformaciones. La normalidad no es un requisito universal de los algoritmos de Machine Learning, por lo que debe estudiarse según el modelo y el objetivo del análisis.

8.9. Análisis de errores

Los residuos se definen como:

$$e_i = y_i - \hat{y}_i.$$

El análisis de residuos permite comprobar sesgos, heterocedasticidad, valores extremos y cambios en el comportamiento del error según el nivel de la variable objetivo.

Capítulo 9

Implementación de conceptos estadísticos utilizando Python como lenguaje de programación

9.1. pandas

```
import pandas as pd

df = pd.read_csv("datos.csv")

print(df.head())
print(df.describe())
print(df.isna().sum())
```

9.2. Media, mediana y desviación

```
media = df["soc"].mean()
mediana = df["soc"].median()
desviacion = df["soc"].std()

print(media, mediana, desviacion)
```

9.3. Correlaciones

```
corr = df.corr(numeric_only=True)
print(corr["soc"].sort_values(ascending=False))
```

9.4. Cuantiles

```
q = df["soc"].quantile([0.25, 0.50, 0.75])
print(q)
```

9.5. Visualización

```
import matplotlib.pyplot as plt

plt.hist(df["soc"].dropna(), bins=20)
plt.xlabel("SOC")
plt.ylabel("Frecuencia")
plt.title("Distribuci n de SOC")
plt.show()
```

9.6. Análisis de residuos

```
residuos = y_true - y_pred

plt.scatter(y_pred, residuos)
plt.axhline(0, linestyle="--")
plt.xlabel("Predicci n")
plt.ylabel("Residuo")
plt.show()
```

9.7. Métricas con scikit-learn

```
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import mean_squared_error, r2_score

mae = mean_absolute_error(y_true, y_pred)
rmse = mean_squared_error(y_true, y_pred) ** 0.5
r2 = r2_score(y_true, y_pred)

print("MAE:", mae)
print("RMSE:", rmse)
print("R2:", r2)
```

Capítulo 10

Puesta en marcha del entorno de trabajo

10.1. Arquitectura del entorno

El entorno recomendado para el curso está compuesto por:

Sistema operativo → Python → Entorno virtual → Librerías → Jupyter/IDE.

10.2. Entornos virtuales

Los entornos virtuales permiten aislar las dependencias de un proyecto.

```
python -m venv .venv
```

En Windows:

```
.venv\Scripts\activate
```

En Linux/macOS:

```
source .venv/bin/activate
```

10.3. Instalación de paquetes

```
python -m pip install --upgrade pip  
pip install numpy pandas matplotlib scikit-learn jupyter
```

10.4. Jupyter

Para iniciar Jupyter:

```
jupyter lab
```

Un notebook permite combinar código, texto, fórmulas, tablas, gráficos y resultados.

10.5. Comprobación del entorno

```
import sys
import numpy
import pandas
import sklearn

print(sys.version)
print("NumPy:", numpy.__version__)
print("pandas:", pandas.__version__)
print("scikit-learn:", sklearn.__version__)
```

10.6. Reproducibilidad

Se recomienda registrar:

- versión de Python;
- versiones de librerías;
- semilla aleatoria;
- fuente de los datos;
- transformaciones realizadas;
- parámetros del modelo.

Capítulo 11

Detalle de los diferentes softwares y programas utilizados para la implementación de algoritmos basados en IA

11.1. Python

Python será el lenguaje principal debido a la disponibilidad de bibliotecas científicas, de análisis de datos y Machine Learning.

11.2. JupyterLab

JupyterLab facilita la experimentación interactiva y la documentación de procesos.

11.3. Visual Studio Code

Visual Studio Code puede utilizarse para desarrollar scripts, módulos, pruebas, notebooks y proyectos completos.

11.4. NumPy

Biblioteca fundamental para cálculo numérico y operaciones vectoriales y matriciales.

11.5. pandas

Biblioteca orientada a la manipulación de datos tabulares y series temporales.

11.6. Matplotlib

Permite construir gráficos para análisis exploratorio y evaluación.

11.7. scikit-learn

Proporciona algoritmos clásicos de Machine Learning, herramientas de preprocesamiento, selección de variables, validación y evaluación.

11.8. Otras bibliotecas

Según la evolución del curso se pueden introducir:

- SciPy para cálculo científico;
- Seaborn para visualización estadística;
- TensorFlow o Keras para Deep Learning;
- PyTorch para redes neuronales;
- XGBoost para boosting;
- SHAP para explicabilidad.

11.9. Control de versiones

Git permite registrar cambios en el código y facilitar el trabajo colaborativo. Una estructura inicial puede ser:

```
proyecto_ia/  
|-- data/  
|-- notebooks/  
|-- src/  
|-- tests/  
|-- models/  
|-- reports/  
|-- requirements.txt  
|-- README.md
```

Capítulo 12

Inmersión en el lenguaje Python

12.1. Variables y tipos

```
nombre = "Ana"  
edad = 25  
altura = 1.68  
activo = True
```

Los tipos básicos incluyen int, float, str y bool.

12.2. Estructuras de datos

```
lista = [10, 20, 30]  
tupla = (10, 20, 30)  
diccionario = {"modelo": "RandomForest", "n_estimators": 100}
```

12.3. Condicionales

```
if edad >= 18:  
    print("Adulto")  
else:  
    print("Menor")
```

12.4. Bucles

```
for valor in [1, 2, 3, 4]:  
    print(valor)
```

12.5. Funciones

```
def rmse(y_true, y_pred):  
    import numpy as np  
    return np.sqrt(np.mean((y_true - y_pred) ** 2))
```

12.6. Comprensiones

```
cuadrados = [x ** 2 for x in range(10)]
```

12.7. Excepciones

```
try:
    valor = float(input("Introduzca un número: "))
except ValueError:
    print("Valor no válido")
```

12.8. Programación orientada a objetos

```
class ModeloIA:
    def __init__(self, nombre):
        self.nombre = nombre

    def describir(self):
        return f"Modelo: {self.nombre}"

modelo = ModeloIA("Random Forest")
print(modelo.describir())
```

12.9. Buenas prácticas

Se introducirán nombres descriptivos, funciones pequeñas, documentación, modularidad, control de excepciones y separación entre configuración, procesamiento y resultados.

Capítulo 13

Resumen

El Tema 1 establece las bases necesarias para comprender el resto de la especialidad IFCD107. Los principales conocimientos adquiridos son:

1. concepto y modalidades de Inteligencia Artificial;
2. principales algoritmos de IA y Machine Learning;
3. aprendizaje supervisado, no supervisado y por refuerzo;
4. fundamentos de álgebra, cálculo y probabilidad;
5. estadística descriptiva y análisis de datos;
6. preprocesamiento y análisis de resultados;
7. Python para cálculo matemático y estadístico;
8. entorno de desarrollo para IA;
9. principales herramientas y bibliotecas;
10. fundamentos de programación en Python.

El flujo conceptual que debe quedar consolidado es:

Problema → Datos → Matemáticas/Estadística → Algoritmo → Entrenamiento → Evaluación → Interpretación
--

Capítulo 14

Actividades tipo test

14.1. Test de conceptos fundamentales

1. ¿Cuál de las siguientes afirmaciones describe mejor Machine Learning?
 - a) Un lenguaje de programación.
 - b) Un conjunto de técnicas que aprenden patrones a partir de datos.
 - c) Un sistema operativo.
 - d) Un formato de almacenamiento.
2. ¿Qué tipo de aprendizaje utiliza datos etiquetados?
 - a) Supervisado.
 - b) No supervisado.
 - c) Exclusivamente por refuerzo.
 - d) Clustering sin etiquetas.
3. ¿Cuál es una tarea de regresión?
 - a) Predecir el precio de una vivienda.
 - b) Determinar si un correo es spam.
 - c) Agrupar clientes.
 - d) Detectar comunidades sin etiquetas.
4. ¿Qué biblioteca se utiliza habitualmente para manipulación tabular?
 - a) pandas.
 - b) Jupyter.
 - c) Git.
 - d) Docker.
5. ¿Qué representa R^2 en un problema de regresión?
 - a) Una medida relacionada con la varianza explicada respecto al modelo base.
 - b) El número de variables.
 - c) La desviación típica.
 - d) El número de árboles.
6. ¿Qué operación representa $\mathbf{X}\mathbf{w}$?
 - a) Multiplicación de una matriz por un vector.
 - b) Suma de una matriz y un vector.
 - c) Resta de una matriz y un vector.
 - d) División de una matriz por un vector.

- a) Una multiplicación matricial.
 - b) Una concatenación de cadenas.
 - c) Una clasificación.
 - d) Un histograma.
7. ¿Qué problema puede producirse si se utiliza información del conjunto de prueba durante el entrenamiento?
- a) Fuga de información.
 - b) Normalización perfecta.
 - c) Clustering.
 - d) Regularización automática.
8. ¿Qué mide principalmente el RMSE?
- a) Magnitud típica del error de predicción en las unidades de la variable objetivo.
 - b) Número de características.
 - c) Número de clases.
 - d) Correlación entre variables.

14.2. Preguntas de desarrollo

1. Diferencie IA, Machine Learning y Deep Learning.
2. Explique las diferencias entre aprendizaje supervisado y no supervisado.
3. Explique por qué es necesario separar entrenamiento y prueba.
4. Describa el concepto de sobreajuste.
5. Explique la utilidad de la media, desviación típica y correlación.
6. Describa el papel de NumPy, pandas y scikit-learn.
7. Explique qué información debe registrarse para reproducir un experimento.

14.3. Práctica final

Construya un notebook que:

1. cargue un dataset;
2. muestre sus dimensiones y tipos;
3. calcule estadísticas descriptivas;
4. detecte valores ausentes;
5. visualice al menos dos variables;
6. separe variables predictoras y objetivo;
7. divida los datos en entrenamiento y prueba;
8. entrene un modelo sencillo;

9. calcule MAE, RMSE y R^2 ;
10. analice los residuos;
11. documente las conclusiones.

14.4. Soluciones orientativas

1. b
2. a
3. a
4. a
5. a
6. a
7. a
8. a

14.5. Checklist de finalización

- ☐ Comprendo las principales modalidades de IA.
- ☐ Distingo clasificación, regresión y clustering.
- ☐ Comprendo la división entrenamiento/prueba.
- ☐ Puedo realizar operaciones vectoriales básicas.
- ☐ Puedo calcular estadísticas descriptivas.
- ☐ Puedo utilizar NumPy y pandas.
- ☐ Puedo construir un modelo básico con scikit-learn.
- ☐ Puedo interpretar MAE, RMSE y R^2 .
- ☐ Puedo crear un notebook reproducible.

Apéndice A

Glosario básico

Algoritmo Procedimiento para resolver un problema.

Feature Variable utilizada como entrada de un modelo.

Target Variable objetivo.

Modelo Representación matemática o computacional utilizada para realizar una tarea.

Entrenamiento Ajuste de un modelo a partir de datos.

Inferencia Obtención de predicciones con un modelo entrenado.

Overfitting Sobreajuste a los datos de entrenamiento.

Generalización Capacidad de funcionar sobre datos no vistos.

Dataset Conjunto estructurado de datos.

Preprocesamiento Transformaciones realizadas antes del entrenamiento.

Apéndice B

Referencia oficial

La estructura de este documento toma como referencia el programa oficial del SEPE para la especialidad IFCD107 – Especialista en Inteligencia Artificial.

- Código: IFCD107.
- Módulo: Fundamentos de Inteligencia Artificial.
- Duración oficial: 42 horas.
- La secuenciación en 12 unidades y su distribución interna son una propuesta didáctica basada en el contenido mostrado en el material de referencia.