

Ejercicios de Estadística Aplicada a la Inteligencia Artificial

Problemas, interpretación y soluciones razonadas

José Manuel Aroca Fernández

2026

Presentación

Este cuaderno complementa el documento *Introducción a la Estadística Aplicada a la Inteligencia Artificial*. La primera parte contiene únicamente los enunciados, organizados por bloques temáticos. La segunda parte reúne las soluciones razonadas, de forma que el material pueda utilizarse tanto para trabajo autónomo como para actividades de aula y evaluación.

Los ejercicios combinan cálculo, interpretación, razonamiento estadístico y aplicaciones a Machine Learning. Salvo indicación contraria, se recomienda justificar los resultados y no limitarse a proporcionar un valor numérico.

Índice general

Presentación	i
I Ejercicios	1
1. Fundamentos de estadística e Inteligencia Artificial	2
2. Estadística descriptiva	3
3. Probabilidad y distribuciones	5
4. Varianza, covarianza, correlación, regresión y PCA	6
5. Evaluación de modelos de Machine Learning	8
6. Sesgo, varianza y sobreajuste	9
7. Muestreo y validación cruzada	10
8. Inferencia estadística e incertidumbre	11
9. Preprocesamiento estadístico	12
10. Aplicación práctica con Python	13
11. Caso integrado: predicción de una variable ambiental	14
II Soluciones razonadas	15
12. Soluciones: fundamentos	16
13. Soluciones: estadística descriptiva	17
14. Soluciones: probabilidad y distribuciones	19
15. Soluciones: covarianza, regresión y PCA	20
16. Soluciones: evaluación	22
17. Soluciones: sesgo y varianza	23
18. Soluciones: muestreo y validación	24
19. Soluciones: inferencia e incertidumbre	25

20.Soluciones: preprocesamiento

26

21.Soluciones: Python

27

22.Soluciones: caso ambiental integrado

29

Parte I

Ejercicios

Capítulo 1

Fundamentos de estadística e Inteligencia Artificial

Ejercicio 1.1: Población y muestra

Un proyecto pretende estimar el carbono orgánico del suelo de todas las parcelas agrícolas de una región. Se dispone de 1 200 muestras de suelo. Identifique la población, la muestra y la variable objetivo.

Ejercicio 1.2: Tipos de variables

Clasifique como nominal, ordinal, discreta o continua: tipo de cultivo, nivel de erosión (bajo/medio/alto), número de parcelas, SOC en g/kg, clase de suelo y número de imágenes válidas.

Ejercicio 1.3: Variable objetivo y predictores

En un modelo que utiliza bandas Sentinel-2, NDVI, altitud y pendiente para predecir SOC, distinga predictores y variable objetivo. Explique qué significaría una predicción $\hat{y}_i$.

Ejercicio 1.4: Representatividad

Explique por qué una muestra formada exclusivamente por parcelas de regadío puede ser inadecuada para construir un modelo destinado a toda una región con regadío y secano.

Ejercicio 1.5: Flujo de Machine Learning

Ordene y justifique: evaluación, recogida de datos, entrenamiento, preprocesamiento, división train/test y análisis exploratorio.

Capítulo 2

Estadística descriptiva

Ejercicio 2.1: Media, mediana y moda

Para los datos

$$X = \{4, 5, 5, 6, 7, 8, 30\}$$

calcule media, mediana y moda. ¿Qué medida representa mejor el centro?

Ejercicio 2.2: Varianza y desviación típica

Para

$$X = \{2, 4, 6, 8\}$$

calcule la media, varianza muestral y desviación típica muestral.

Ejercicio 2.3: Cuartiles e IQR

Una variable presenta $Q_1 = 12$ y $Q_3 = 20$. Calcule el IQR y los límites habituales de detección de atípicos basados en $1.5 IQR$.

Ejercicio 2.4: Efecto de un outlier

Compare descriptivamente:

$$A = \{48, 49, 50, 51, 52\}$$

y

$$B = \{48, 49, 50, 51, 500\}.$$

Explique el efecto sobre media y varianza.

Ejercicio 2.5: Escalas diferentes

Dos variables tienen:

$$X : \mu = 0.4, s = 0.1, \quad Y : \mu = 1200, s = 350.$$

¿Por qué puede ser conveniente estandarizarlas antes de ciertos algoritmos?

Ejercicio 2.6: Distribución del objetivo

Un dataset de regresión tiene una variable objetivo muy asimétrica, con muchas observaciones pequeñas y unas pocas extremadamente grandes. Indique qué estadísticas y gráficos analizaría antes de entrenar.

Capítulo 3

Probabilidad y distribuciones

Ejercicio 3.1: Probabilidad básica

De 200 parcelas, 80 son de secano. Si se elige una al azar, calcule la probabilidad de seleccionar una parcela de secano.

Ejercicio 3.2: Probabilidad condicionada

De 100 parcelas con SOC alto, 70 son de regadío. Calcule $P(\text{regadío} \mid \text{SOC alto})$.

Ejercicio 3.3: Regla del producto

Si $P(A) = 0.4$ y $P(B \mid A) = 0.75$, calcule $P(A \cap B)$.

Ejercicio 3.4: Distribución normal

Una variable se aproxima por una normal con $\mu = 50$ y $\sigma = 5$. Calcule el valor tipificado z de una observación $x = 60$ e interprete.

Ejercicio 3.5: Distribuciones

Asocie una distribución razonable a cada caso: número de éxitos en 20 ensayos independientes, tiempo continuo de una medición aproximadamente simétrica, y número de eventos raros por unidad temporal.

Capítulo 4

Varianza, covarianza, correlación, regresión y PCA

Ejercicio 4.1: Covarianza

Para

$$X = \{1, 2, 3, 4\}, \quad Y = \{2, 4, 6, 8\},$$

calcule la covarianza muestral e interprete el signo.

Ejercicio 4.2: Covarianza negativa

Para

$$X = \{1, 2, 3, 4\}, \quad Z = \{5, 4, 3, 2\},$$

calcule la covarianza muestral.

Ejercicio 4.3: Matriz de covarianzas

Usando X , Y y Z de los ejercicios anteriores, construya la matriz de covarianzas.

Ejercicio 4.4: Correlación no implica causalidad

Se observa una correlación elevada entre dos variables ambientales. Explique por qué no es suficiente para concluir que una causa la otra.

Ejercicio 4.5: Regresión lineal

Interprete los parámetros de

$$\hat{y} = 12 + 3.5x.$$

Calcule la predicción para $x = 4$.

Ejercicio 4.6: PCA

Para la matriz de covarianzas

$$\Sigma = \begin{pmatrix} 1.667 & 3.333 & -1.667 \\ 3.333 & 6.667 & -3.333 \\ -1.667 & -3.333 & 1.667 \end{pmatrix},$$

los autovalores son aproximadamente 10, 0, 0. Calcule la varianza explicada de cada compo-

nente e interprete.

Ejercicio 4.7: PCA y escalado

Explique por qué puede ser necesario estandarizar variables antes de PCA cuando se miden en escalas muy diferentes.

Capítulo 5

Evaluación de modelos de Machine Learning

Ejercicio 5.1: Errores

Para

$$y = \{10, 20, 30\}, \quad \hat{y} = \{12, 18, 33\},$$

calcule los residuos $e_i = y_i - \hat{y}_i$.

Ejercicio 5.2: MAE

Con los datos anteriores, calcule el MAE.

Ejercicio 5.3: RMSE

Con los mismos datos, calcule el RMSE.

Ejercicio 5.4: MAE frente a RMSE

Explique por qué RMSE penaliza más los errores grandes que MAE.

Ejercicio 5.5: Interpretación de R^2

Un modelo obtiene $R^2 = 0.72$. Explique qué información proporciona y qué aspectos no permite concluir por sí solo.

Ejercicio 5.6: Comparación de modelos

Modelo A: RMSE=12, MAE=6. Modelo B: RMSE=9, MAE=8. Analice qué información sugieren las métricas sin declarar automáticamente un modelo superior.

Capítulo 6

Sesgo, varianza y sobreajuste

Ejercicio 6.1: Subajuste

Un modelo obtiene $\text{RMSE}_{\text{train}}=25$ y $\text{RMSE}_{\text{test}}=27$. Ambos valores son altos respecto a la escala del problema. Indique un diagnóstico posible.

Ejercicio 6.2: Sobreajuste

Un modelo obtiene $R^2_{\text{train}} = 0.99$ y $R^2_{\text{test}} = 0.48$. Explique el patrón observado.

Ejercicio 6.3: Variabilidad entre folds

Los valores de R^2 son:

0.91, 0.62, 0.84, 0.39, 0.77.

Calcule la media y la amplitud. Interprete la estabilidad.

Ejercicio 6.4: Regularización Ridge

Explique el papel de λ en

$$\mathcal{L} = \sum (y_i - \hat{y}_i)^2 + \lambda \sum \beta_j^2.$$

¿Qué puede ocurrir si λ es excesivamente grande?

Ejercicio 6.5: Datos frente a modelo

Explique la diferencia entre varianza de una variable de entrada y varianza de las predicciones de un modelo ante diferentes muestras de entrenamiento.

Ejercicio 6.6: Complejidad

Describa cómo suelen evolucionar el error de entrenamiento y el error de prueba cuando aumenta progresivamente la complejidad de un modelo.

Capítulo 7

Muestreo y validación cruzada

Ejercicio 7.1: Train/Test

Un dataset contiene 2 000 observaciones. Se reserva el 20 % para test. ¿Cuántas observaciones quedan en train y test?

Ejercicio 7.2: K-fold

Explique el funcionamiento de una validación cruzada 5-fold.

Ejercicio 7.3: Promedio de folds

Un modelo obtiene RMSE:

8.2, 7.9, 8.5, 8.1, 8.3.

Calcule el RMSE medio.

Ejercicio 7.4: Dependencia espacial

Explique por qué un K-fold aleatorio puede proporcionar una estimación optimista cuando existen observaciones espacialmente próximas.

Ejercicio 7.5: Dependencia temporal

Para un problema de predicción temporal, explique por qué no debería entrenarse con observaciones futuras para predecir el pasado.

Capítulo 8

Inferencia estadística e incertidumbre

Ejercicio 8.1: Estimación puntual

Una muestra tiene media $\bar{x} = 42$. ¿Cuál es la estimación puntual natural de la media poblacional μ ?

Ejercicio 8.2: Error estándar

Si $s = 10$ y $n = 100$, calcule el error estándar aproximado de la media:

$$SE = \frac{s}{\sqrt{n}}.$$

Ejercicio 8.3: Intervalo aproximado

Usando $\bar{x} = 42$ y $SE = 1$, construya un intervalo aproximado del 95 % mediante $\bar{x} \pm 1.96SE$.

Ejercicio 8.4: Interpretación de intervalos

Explique cuidadosamente qué significa un intervalo de confianza del 95 % desde el punto de vista del procedimiento repetido.

Ejercicio 8.5: Incertidumbre predictiva

Indique tres fuentes distintas de incertidumbre que pueden afectar a una predicción de Machine Learning.

Capítulo 9

Preprocesamiento estadístico

Ejercicio 9.1: Estandarización

Para una observación $x = 70$, con media $\mu = 50$ y desviación típica $\sigma = 10$, calcule:

$$z = \frac{x - \mu}{\sigma}.$$

Ejercicio 9.2: Datos ausentes

Una variable tiene 35 % de valores ausentes. Proponga comprobaciones que realizaría antes de decidir entre imputar o eliminar la variable.

Ejercicio 9.3: Outliers

Un sensor registra un valor diez veces superior al rango físico posible. Describa un procedimiento de revisión antes de eliminarlo.

Ejercicio 9.4: Data leakage

Explique por qué ajustar un `StandardScaler` con train y test juntos antes de evaluar constituye fuga de información.

Ejercicio 9.5: Pipeline

Ordene correctamente: PCA, modelo, `StandardScaler` y división train/test.

Capítulo 10

Aplicación práctica con Python

Ejercicio 10.1: Pandas

Escriba código para cargar `datos.csv`, mostrar las primeras cinco filas y obtener estadísticas descriptivas.

Ejercicio 10.2: Covarianza y correlación

Escriba código con pandas para calcular matrices de covarianza y correlación de un Data-Frame `df`.

Ejercicio 10.3: PCA

Escriba un fragmento de código que estandarice X y aplique PCA conservando al menos el 95 % de la varianza.

Ejercicio 10.4: Pipeline

Construya un `Pipeline` con `StandardScaler`, `PCA` y `RandomForestRegressor`.

Ejercicio 10.5: Evaluación

Escriba código para calcular MAE, RMSE y R^2 a partir de `y_test` y `y_pred`.

Capítulo 11

Caso integrado: predicción de una variable ambiental

Ejercicio 11.1: Diseño experimental

Se desea predecir SOC utilizando bandas Sentinel-2, índices espectrales y variables topográficas. Proponga una estructura de dataset indicando predictores, objetivo y metadatos útiles.

Ejercicio 11.2: Exploración

Enumere al menos ocho comprobaciones estadísticas que realizaría antes de entrenar el modelo.

Ejercicio 11.3: Validación espacial

Proponga una estrategia de validación para reducir el riesgo de que puntos muy próximos aparezcan simultáneamente en train y test.

Ejercicio 11.4: Comparación con y sin PCA

Diseñe un experimento para comprobar si PCA mejora el pipeline predictivo. Indique qué debe mantenerse constante para que la comparación sea válida.

Ejercicio 11.5: Informe final

Indique qué métricas, gráficos y análisis de incertidumbre incluiría en un informe técnico de un modelo de regresión ambiental.

Parte II

Soluciones razonadas

Capítulo 12

Soluciones: fundamentos

Solución del ejercicio 1.1

La población está formada por todas las parcelas agrícolas de interés de la región; la muestra son las 1 200 observaciones de suelo disponibles; la variable objetivo es el SOC que se desea estimar.

Solución del ejercicio 1.2

Tipo de cultivo: nominal. Nivel de erosión: ordinal. Número de parcelas: discreta. SOC: continua. Clase de suelo: nominal. Número de imágenes válidas: discreta.

Solución del ejercicio 1.3

Las bandas Sentinel-2, NDVI, altitud y pendiente son predictores. SOC es la variable objetivo. $\hat{y}_i$ es la estimación de SOC producida por el modelo para la observación i .

Solución del ejercicio 1.4

La muestra no representa las condiciones de secano. El modelo puede aprender relaciones específicas del regadío y producir un error de generalización elevado cuando se aplique al resto de la población.

Solución del ejercicio 1.5

Un orden razonable es: recogida de datos, análisis exploratorio, división train/test, preprocesamiento ajustado sobre train, entrenamiento y evaluación sobre datos no utilizados para el ajuste.

Capítulo 13

Soluciones: estadística descriptiva

Solución del ejercicio 2.1

$$\bar{x} = \frac{65}{7} \approx 9.29.$$

La mediana es 6 y la moda es 5. La media queda desplazada por 30; para describir el centro de este pequeño conjunto asimétrico, la mediana resulta más robusta.

Solución del ejercicio 2.2

$$\bar{x} = 5.$$

Las desviaciones son $-3, -1, 1, 3$ y sus cuadrados suman 20:

$$s^2 = \frac{20}{3} \approx 6.67, \quad s \approx 2.58.$$

Solución del ejercicio 2.3

$$IQR = 20 - 12 = 8.$$

Límite inferior:

$$12 - 1.5(8) = 0.$$

Límite superior:

$$20 + 1.5(8) = 32.$$

Solución del ejercicio 2.4

En A la media es 50 y la dispersión es pequeña. En B , 500 desplaza fuertemente la media y, debido al cuadrado de las desviaciones, aumenta mucho la varianza. El valor debe investigarse antes de eliminarlo.

Solución del ejercicio 2.5

La escala de Y domina numéricamente a la de X . Algoritmos sensibles a distancias, magnitudes o penalizaciones pueden quedar condicionados por esta diferencia. La estandarización lleva las variables a una escala comparable.

Solución del ejercicio 2.6

Conviene estudiar media, mediana, desviación típica, cuartiles, percentiles, IQR, mínimos/máximos, histograma, boxplot y, cuando proceda, transformaciones como logaritmos. También debe comprobarse si los valores extremos son errores o casos reales.

Capítulo 14

Soluciones: probabilidad y distribuciones

Solución del ejercicio 3.1

$$P(\text{secano}) = \frac{80}{200} = 0.4.$$

Solución del ejercicio 3.2

$$P(\text{regadío} \mid \text{SOC alto}) = \frac{70}{100} = 0.7.$$

Solución del ejercicio 3.3

$$P(A \cap B) = P(A)P(B \mid A) = 0.4(0.75) = 0.30.$$

Solución del ejercicio 3.4

$$z = \frac{60 - 50}{5} = 2.$$

La observación está dos desviaciones típicas por encima de la media.

Solución del ejercicio 3.5

Número de éxitos en un número fijo de ensayos: binomial. Medición continua aproximadamente simétrica: normal, si los supuestos son razonables. Número de eventos raros por unidad temporal: Poisson en un modelo básico.

Capítulo 15

Soluciones: covarianza, regresión y PCA

Solución del ejercicio 4.1

Las medias son $\bar{X} = 2.5$ y $\bar{Y} = 5$. La suma de productos centrados es 10:

$$\text{Cov}(X, Y) = \frac{10}{3} \approx 3.333.$$

El signo positivo indica variación conjunta en el mismo sentido.

Solución del ejercicio 4.2

$$\text{Cov}(X, Z) = \frac{-5}{3} \approx -1.667.$$

Cuando X aumenta, Z disminuye.

Solución del ejercicio 4.3

$$\Sigma = \begin{pmatrix} 1.667 & 3.333 & -1.667 \\ 3.333 & 6.667 & -3.333 \\ -1.667 & -3.333 & 1.667 \end{pmatrix}.$$

La diagonal contiene las varianzas.

Solución del ejercicio 4.4

La correlación cuantifica asociación lineal, pero no establece dirección causal. Pueden existir variables de confusión, causalidad inversa o una relación producida por el diseño muestral.

Solución del ejercicio 4.5

12 es el intercepto y 3.5 el incremento esperado de la predicción por unidad de x :

$$\hat{y} = 12 + 3.5(4) = 26.$$

Solución del ejercicio 4.6

La suma de autovalores es 10. Por tanto:

$$EVR_1 = 10/10 = 1, \quad EVR_2 = 0, \quad EVR_3 = 0.$$

La primera componente explica el 100 % de la varianza en este ejemplo idealizado.

Solución del ejercicio 4.7

PCA maximiza varianza. Si una variable tiene una escala numérica mucho mayor, puede dominar la matriz de covarianzas. Estandarizar es habitual cuando las unidades o escalas no son comparables.

Capítulo 16

Soluciones: evaluación

Solución del ejercicio 5.1

$$e = \{-2, 2, -3\}.$$

Solución del ejercicio 5.2

$$MAE = \frac{2 + 2 + 3}{3} = \frac{7}{3} \approx 2.33.$$

Solución del ejercicio 5.3

$$RMSE = \sqrt{\frac{(-2)^2 + 2^2 + (-3)^2}{3}} = \sqrt{\frac{17}{3}} \approx 2.38.$$

Solución del ejercicio 5.4

RMSE eleva al cuadrado los errores antes de promediarlos, de modo que un error grande incrementa la métrica de forma más intensa que en MAE.

Solución del ejercicio 5.5

En el conjunto y procedimiento de evaluación considerados, $R^2 = 0.72$ indica que el modelo explica una fracción importante de la variabilidad respecto a la referencia usada. No informa por sí solo sobre sesgo de residuos, errores extremos, transferencia espacial/temporal o incertidumbre.

Solución del ejercicio 5.6

A presenta MAE menor pero RMSE mayor, lo que sugiere que puede contener algunos errores grandes. B tiene RMSE menor pero MAE mayor. La elección depende del coste de errores grandes, la distribución de residuos y el objetivo del problema.

Capítulo 17

Soluciones: sesgo y varianza

Solución del ejercicio 6.1

Un diagnóstico posible es subajuste: train y test son similares pero ambos presentan error alto. Deben revisarse complejidad, variables y calidad de datos.

Solución del ejercicio 6.2

La diferencia muy grande entre train y test es compatible con sobreajuste: el modelo reproduce muy bien entrenamiento pero generaliza peor.

Solución del ejercicio 6.3

$$\bar{R}^2 = \frac{3.53}{5} = 0.706.$$

Amplitud:

$$0.91 - 0.39 = 0.52.$$

La variabilidad entre folds es considerable y conviene investigar la representatividad de las particiones.

Solución del ejercicio 6.4

λ controla la intensidad de la penalización. Si es demasiado grande, los coeficientes pueden reducirse excesivamente y aumentar el sesgo, produciendo subajuste.

Solución del ejercicio 6.5

La varianza de una entrada mide dispersión de sus valores. La varianza del modelo se refiere a cuánto cambian sus predicciones cuando se entrena con muestras diferentes.

Solución del ejercicio 6.6

Al aumentar complejidad, el error train suele disminuir. El error test puede disminuir inicialmente y aumentar después cuando el modelo empieza a sobreajustar.

Capítulo 18

Soluciones: muestreo y validación

Solución del ejercicio 7.1

Test: $2000(0.20) = 400.$

Train: $2000 - 400 = 1600.$

Solución del ejercicio 7.2

Los datos se dividen en cinco partes. En cada iteración se utilizan cuatro para entrenar y una para validar. Cada fold actúa una vez como validación y las métricas se agregan.

Solución del ejercicio 7.3

$$\overline{RMSE} = \frac{8.2 + 7.9 + 8.5 + 8.1 + 8.3}{5} = 8.2.$$

Solución del ejercicio 7.4

Puntos próximos pueden compartir condiciones y ser muy parecidos. Si unos quedan en train y otros en test, la evaluación puede beneficiarse de esa dependencia. Una partición por bloques espaciales es una alternativa.

Solución del ejercicio 7.5

Usar el futuro para predecir el pasado introduce información no disponible en el momento real de predicción. Debe respetarse el orden temporal.

Capítulo 19

Soluciones: inferencia e incertidumbre

Solución del ejercicio 8.1

La estimación puntual natural es:

$$\hat{\mu} = \bar{x} = 42.$$

Solución del ejercicio 8.2

$$SE = \frac{10}{\sqrt{100}} = 1.$$

Solución del ejercicio 8.3

$$42 \pm 1.96(1) = [40.04, 43.96].$$

Solución del ejercicio 8.4

En repeticiones hipotéticas del procedimiento de muestreo y construcción del intervalo, aproximadamente el 95 % de los intervalos obtenidos contendrían el parámetro verdadero bajo los supuestos del método.

Solución del ejercicio 8.5

Ejemplos: ruido de medida, variabilidad de la muestra, incertidumbre del modelo, cambio de distribución, incertidumbre de parámetros y variabilidad intrínseca del fenómeno.

Capítulo 20

Soluciones: preprocesamiento

Solución del ejercicio 9.1

$$z = \frac{70 - 50}{10} = 2.$$

Solución del ejercicio 9.2

Debe estudiarse el mecanismo de ausencia, su relación con objetivo y otras variables, distribución por grupos, utilidad de la variable, calidad de la fuente y efecto de diferentes estrategias de imputación dentro de validación.

Solución del ejercicio 9.3

Comprobar unidad, límites físicos, metadatos, calibración, fecha, sensor, duplicados y fuente original. Si se confirma error, documentar la corrección o exclusión.

Solución del ejercicio 9.4

La media y desviación usadas por el scaler contendrían información del test. El preprocesador debe ajustarse únicamente con train y luego transformar test.

Solución del ejercicio 9.5

Primero se divide train/test. Después, dentro del flujo ajustado con train: StandardScaler → PCA → modelo.

Capítulo 21

Soluciones: Python

Solución del ejercicio 10.1

```
1 import pandas as pd
2
3 df = pd.read_csv("datos.csv")
4 print(df.head())
5 print(df.describe())
```

Solución del ejercicio 10.2

```
1 cov = df.cov(numeric_only=True)
2 corr = df.corr(numeric_only=True)
3 print(cov)
4 print(corr)
```

Solución del ejercicio 10.3

```
1 from sklearn.preprocessing import StandardScaler
2 from sklearn.decomposition import PCA
3
4 X_scaled = StandardScaler().fit_transform(X)
5 pca = PCA(n_components=0.95)
6 X_pca = pca.fit_transform(X_scaled)
```

En evaluación real, scaler y PCA deben ajustarse únicamente con train, preferiblemente mediante un Pipeline.

Solución del ejercicio 10.4

```
1 from sklearn.pipeline import Pipeline
2 from sklearn.preprocessing import StandardScaler
3 from sklearn.decomposition import PCA
4 from sklearn.ensemble import RandomForestRegressor
5
6 pipe = Pipeline([
7     ("scaler", StandardScaler()),
8     ("pca", PCA(n_components=0.95)),
9     ("model", RandomForestRegressor(
```

```
10     n_estimators=200,  
11     random_state=42  
12 ))  
13 ])
```

Solución del ejercicio 10.5

```
1 from sklearn.metrics import (  
2     mean_absolute_error,  
3     mean_squared_error,  
4     r2_score  
5 )  
6  
7 mae = mean_absolute_error(y_test, y_pred)  
8 rmse = mean_squared_error(  
9     y_test, y_pred  
10 ) ** 0.5  
11 r2 = r2_score(y_test, y_pred)
```

Capítulo 22

Soluciones: caso ambiental integrado

Solución del ejercicio 11.1

Cada fila puede representar una observación de suelo. Predictores: bandas, índices, DEM, pendiente u otras variables. Objetivo: SOC. Metadatos útiles: coordenadas, fecha, sensor, uso/cobertura, campaña, parcela y calidad.

Solución del ejercicio 11.2

Por ejemplo: tamaño muestral, ausentes, duplicados, rango físico, media, mediana, desviación, percentiles, outliers, histogramas, distribución de SOC, correlaciones, covarianzas, distribución espacial y diferencias por uso del suelo.

Solución del ejercicio 11.3

Puede utilizarse validación por bloques espaciales o grupos geográficos, manteniendo áreas próximas dentro del mismo fold para reducir dependencia entre train y validación.

Solución del ejercicio 11.4

Construir dos pipelines idénticos salvo PCA. Usar las mismas particiones, métricas, semillas cuando proceda, variables iniciales y procedimiento de ajuste. Comparar métricas y estabilidad entre folds, además del número de componentes y coste computacional.

Solución del ejercicio 11.5

Incluiría MAE, RMSE, R^2 , distribución y gráficos de residuos, observado frente a predicho, error por rangos de SOC, rendimiento por región o uso del suelo, validación espacial/temporal, variabilidad entre folds e intervalos o estimaciones de incertidumbre cuando el método lo permita.