

Guía de Laboratorio Jupyter

Algoritmos fundamentales de Machine Learning

Material docente

29 de septiembre de 2026

Resumen

Esta guía acompaña a un conjunto de notebooks Jupyter diseñados para demostrar de forma progresiva el funcionamiento de siete algoritmos fundamentales de Machine Learning: regresión lineal, regresión polinómica, regresión logística, K-means, K-Nearest Neighbors, Máquinas de Vectores de Soporte y Random Forest.

Cada práctica combina explicación conceptual, ejecución de código, visualización, evaluación y reflexión. Los ejemplos utilizan datos sintéticos con finalidad didáctica, de modo que cada notebook pueda ejecutarse de forma autónoma.

Cómo utilizar esta guía

0.1. Estructura del laboratorio

El laboratorio se compone de un notebook índice y siete notebooks independientes:

N.º	Notebook	Contenido
00	00_Indice_Laboratorio_ML.ipynb	Organización del laboratorio
01	01_Regresion_Lineal.ipynb	Regresión lineal
02	02_Regresion_Polinomica.ipynb	Relaciones no lineales
03	03_Regresion_Logistica.ipynb	Clasificación binaria
04	04_Kmeans.ipynb	Clustering
05	05_KNN.ipynb	Vecinos próximos
06	06_SVM.ipynb	Margen y kernels
07	07_Random_Forest.ipynb	Ensemble de árboles

0.2. Preparación del entorno

Se recomienda disponer de Python 3 y Jupyter Notebook o JupyterLab. Las principales dependencias son:

```
numpy
pandas
matplotlib
scikit-learn
```

En un entorno nuevo pueden instalarse mediante:

```
%pip install numpy pandas matplotlib scikit-learn
```

0.3. Metodología de trabajo

Cada notebook debe ejecutarse de forma secuencial:

1. Leer el objetivo de la práctica.
2. Ejecutar la celda de preparación.
3. Observar los datos antes de entrenar.
4. Ejecutar el entrenamiento.
5. Interpretar las visualizaciones.
6. Evaluar el modelo.
7. Modificar al menos un parámetro.

8. Comparar los resultados.
9. Responder las preguntas de reflexión.

Idea clave

El objetivo no es solamente obtener una métrica elevada. La finalidad del laboratorio es relacionar el algoritmo con el tipo de problema, comprender sus mecanismos y observar cómo cambian sus resultados al modificar sus parámetros.

Regresión lineal

0.4. Objetivo

El primer notebook introduce el aprendizaje supervisado para regresión. La variable objetivo es numérica continua.

Objetivos de la práctica

- Crear un conjunto de datos sencillo.
- Ajustar una recta de regresión.
- Interpretar intercepto y pendiente.
- Visualizar predicciones.
- Calcular R^2 , MAE y RMSE.

0.5. Idea matemática

El modelo de regresión lineal simple es:

$$\hat{y} = \beta_0 + \beta_1 x.$$

Los parámetros se estiman minimizando:

$$\min_{\beta_0, \beta_1} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

El residuo de una observación es:

$$e_i = y_i - \hat{y}_i.$$

0.6. Flujo del notebook

1. Crear las horas de estudio y las notas.
2. Representar los puntos.
3. Entrenar `LinearRegression`.
4. Mostrar intercepto y pendiente.
5. Dibujar la recta.
6. Calcular métricas.
7. Predecir la nota para una nueva cantidad de horas.

Actividad propuesta

Modificar los datos de ejemplo introduciendo una observación atípica. Observar cómo cambia la recta y las métricas.

0.7. Preguntas

1. ¿Qué representa β_0 ?
2. ¿Qué representa β_1 ?
3. ¿Qué significa un R^2 próximo a 1?
4. ¿Por qué RMSE puede ser mayor que MAE?
5. ¿Qué ocurre si añadimos un valor atípico?

Regresión polinómica

0.8. Objetivo

Esta práctica introduce una relación no lineal mediante características polinómicas.

Objetivos de la práctica

- Comparar un modelo lineal y uno polinómico.
- Comprender el efecto del grado.
- Observar la relación entre complejidad y sobreajuste.
- Utilizar `PolynomialFeatures` y un `Pipeline`.

0.9. Modelo

Un modelo de grado n tiene la forma:

$$\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_n x^n.$$

El notebook compara los grados 1, 2, 3 y 5.

0.10. Experimento

Se parte de una relación con forma de curva. Después se representan simultáneamente distintos grados.

Actividad propuesta

Ejecutar el notebook y comparar visualmente los modelos. A continuación, calcular las métricas sobre un conjunto de prueba en lugar de utilizar únicamente los datos empleados para ajustar el modelo.

Aspectos a tener en cuenta

Una mejora del ajuste sobre los datos de entrenamiento no implica necesariamente una mejora de generalización. El grado del polinomio debe evaluarse mediante validación.

Regresión logística

0.11. Objetivo

La regresión logística introduce la clasificación binaria.

Objetivos de la práctica

- Crear dos clases.
- Estimar probabilidades.
- Visualizar la frontera de decisión.
- Comprender el papel del umbral.
- Calcular métricas de clasificación.

0.12. Modelo matemático

Primero se calcula:

$$z = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n.$$

Después:

$$p(y = 1 | X) = \frac{1}{1 + e^{-z}}.$$

Una regla de decisión con umbral t puede escribirse como:

$$\hat{y} = \begin{cases} 1 & p(y = 1 | X) \geq t, \\ 0 & p(y = 1 | X) < t. \end{cases}$$

0.13. Experimento

El notebook genera datos bidimensionales y entrena `LogisticRegression`. La visualización permite observar las probabilidades y la frontera correspondiente a $P(y = 1) = 0.5$.

Actividad propuesta

Cambiar el umbral de decisión y estudiar cómo cambia la matriz de confusión, especialmente precision y recall.

K-means

0.14. Objetivo

K-means introduce el aprendizaje no supervisado. No se proporcionan etiquetas de clase.

Objetivos de la práctica

- Comprender el concepto de cluster.
- Explorar distintos valores de K .
- Utilizar el método del codo.
- Visualizar centroides.
- Interpretar la asignación de puntos.

0.15. Algoritmo

K-means alterna dos operaciones:

1. Asignación: cada punto se asigna al centroide más próximo.
2. Actualización: cada centroide se recalcula como la media de los puntos asignados.

La función objetivo habitual es:

$$J = \sum_k = 1^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2.$$

0.16. Experimento

El notebook utiliza `make` `blob` para generar tres agrupaciones. Posteriormente se estudia la inercia para distintos valores de K .

Actividad propuesta

Ejecutar el experimento con $K = 2$, $K = 3$ y $K = 5$. Comparar la estructura obtenida con la distribución visual de los datos.

Aspectos a tener en cuenta

La inercia siempre puede disminuir al aumentar K . Por ello, el método del codo es una herramienta exploratoria y debe interpretarse junto con el contexto del problema.

K-Nearest Neighbors

0.17. Objetivo

K-NN utiliza la proximidad entre observaciones para realizar una clasificación o una regresión.

0.18. Distancia

La distancia euclídea se expresa como:

$$d(x, x_i) = \sqrt{\sum_{j=1}^n (x_j - x_{ij})^2}.$$

0.19. Funcionamiento

1. Calcular las distancias.
2. Ordenar los ejemplos.
3. Seleccionar los K vecinos.
4. Clasificar mediante votación o predecir mediante agregación.

El notebook incorpora StandardScaler porque las variables con escalas diferentes pueden distorsionar las distancias.

Actividad propuesta

Comparar $K = 1$, $K = 3$, $K = 5$, $K = 15$ y $K = 30$. Observar la frontera y la accuracy sobre el conjunto de prueba.

Aspectos a tener en cuenta

K-NN no construye un modelo paramétrico complejo durante el entrenamiento; gran parte del coste aparece durante la predicción, cuando se calculan distancias respecto a los ejemplos almacenados.

Máquinas de Vectores de Soporte

0.20. Objetivo

Esta práctica muestra cómo SVM puede construir fronteras lineales y no lineales mediante kernels.

0.21. Margen

Para un problema lineal separable, una formulación simplificada es:

$$\min \frac{1}{2} \|w\|^2$$

sujeto a:

$$y_i(w^T x_i + b) \geq 1.$$

Los puntos próximos a la frontera son los vectores de soporte.

0.22. Kernels

Cuando la separación lineal no es suficiente, el notebook compara:

- kernel lineal;
- kernel RBF.

Los kernels permiten representar relaciones no lineales sin construir explícitamente todas las características del espacio transformado.

0.23. Experimentos

El notebook utiliza datos generados con `make circles`.

1. Entrenar SVM lineal.
2. Entrenar SVM con RBF.
3. Visualizar ambas fronteras.
4. Contar los vectores de soporte.
5. Modificar C .

Actividad propuesta

Probar $C = 0.1$, $C = 1$, $C = 10$ y $C = 100$. Explicar qué cambio se observa en la frontera y en la capacidad de ajuste.

Random Forest

0.24. Objetivo

Random Forest introduce el aprendizaje ensemble mediante múltiples árboles de decisión.

Objetivos de la práctica

- Construir un conjunto de árboles.
- Comprender el papel de *bootstrap*.
- Analizar el efecto de n *estimators*.
- Estudiar la importancia de variables.
- Evaluar el conjunto mediante datos de prueba.

0.25. Principio

Para clasificación, la predicción final puede obtenerse mediante voto mayoritario:

$$\hat{y} = \text{modo}\{f_1(x), f_2(x), \dots, f_T(x)\}.$$

Para regresión, puede utilizarse el promedio:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T f_t(x).$$

0.26. Experimento

El notebook:

1. Genera datos de clasificación.
2. Divide los datos en entrenamiento y prueba.
3. Entrena RandomForestClassifier.
4. Evalúa accuracy.
5. Calcula importancia de variables.
6. Compara distintos números de árboles.

Actividad propuesta

Comparar n

$estimators = 1, 5, 10, 50, 100, 200$. Analizar si añadir árboles modifica de forma apreciable la precisión sobre el conjunto de prueba.

Comparación de los algoritmos

Algoritmo	Aprendizaje	Problema	Principio
Regresión lineal	Supervisado	Regresión	Ajuste de una relación lineal.
Regresión polinómica	Supervisado	Regresión	Extensión mediante potencias.
Regresión logística	Supervisado	Clasificación	Probabilidad mediante función sigmoide.
K-means	No supervisado	Clustering	Agrupación alrededor de centroides.
K-NN	Supervisado	Clasificación/regresión	Similitud mediante distancia.
SVM	Supervisado	Clasificación/regresión	Márgen, hiperplano y kernels.
Random Forest	Supervisado	Clasificación/regresión	Agregación de árboles.

0.27. Mapa de decisión para el laboratorio

Como guía de aprendizaje:

1. Si el objetivo es un valor continuo, comenzar estudiando regresión lineal.
2. Si aparece una relación curva, estudiar regresión polinómica.
3. Si el objetivo es una clase binaria, estudiar regresión logística.
4. Si no existen etiquetas y se quieren descubrir grupos, estudiar K-means.
5. Si la similitud local es importante, estudiar K-NN.
6. Si se necesita una frontera basada en margen o relaciones no lineales mediante kernels, estudiar SVM.
7. Si se quiere estudiar un ensemble de árboles, utilizar Random Forest.

Este esquema es una guía conceptual de aprendizaje, no una regla absoluta para seleccionar modelos en proyectos reales.

Actividad integradora

0.28. Objetivo

El alumno debe utilizar al menos tres de los notebooks para resolver el mismo problema de clasificación o regresión y comparar los resultados.

0.29. Propuesta

1. Seleccionar un conjunto de datos.
2. Definir la variable objetivo.
3. Identificar si el problema es clasificación, regresión o aprendizaje no supervisado.
4. Preparar los datos.
5. Entrenar tres algoritmos.
6. Utilizar una estrategia de validación coherente.
7. Comparar las métricas.
8. Representar gráficamente los resultados.
9. Analizar errores y limitaciones.
10. Justificar la configuración experimental.

Actividad propuesta

El resultado final debe ser un notebook reproducible que contenga: objetivo, descripción de datos, preparación, modelos, métricas, visualizaciones, comparación y conclusiones.

Ficha de evaluación del laboratorio

Criterio	Peso	Evidencia
Comprensión del algoritmo	20 %	Explicación del funcionamiento
Preparación de datos	15 %	Código y justificación
Implementación	20 %	Notebook ejecutable
Evaluación	20 %	Métricas y visualizaciones
Análisis crítico	15 %	Interpretación y limitaciones
Reproducibilidad	10 %	Código organizado y documentado

Checklist del alumno

Antes de entregar cada notebook:

- ☐ He explicado el problema.
- ☐ He descrito los datos.
- ☐ He ejecutado todas las celdas.
- ☐ He visualizado los datos.
- ☐ He entrenado el modelo.
- ☐ He evaluado el resultado.
- ☐ He probado al menos un parámetro diferente.
- ☐ He interpretado las métricas.
- ☐ He identificado limitaciones.
- ☐ El notebook se ejecuta de principio a fin.

Conclusión

El laboratorio proporciona una progresión práctica desde modelos lineales hasta métodos basados en distancia, kernels y ensembles. La ejecución de los notebooks debe complementarse con la interpretación de las visualizaciones, la evaluación sobre datos no utilizados para el ajuste y la reflexión sobre las limitaciones de cada método.

El objetivo final es que el alumno no solamente sepa ejecutar `fit()` y `predict()`, sino que pueda explicar qué está haciendo el algoritmo, qué supuestos o decisiones intervienen y cómo comprobar si los resultados son razonables.